

Marko Žuraj

0016157908

Martina Vincijanović

0016161848

Mia Šižgorić

0016160216

Gabriela Perković

0016161159

Melaniya Jedvaj

0016165324

Ela Biršl

0016168672

Patricija Pofuk

0016167542

Ena Horvat

0016165184

Helena Bedeković

0016168849

Optimizacija digitalne prodaje vozila pomoću analitičkih preporuka

Emil Frey Digital - Fakultet organizacije i informatike

Sadržaj

1. Opis poduzeća
2. Opis usluga
3. Analiza tržišta i konkurencije
 - 3.1. Ciljne skupine
 - 3.2. Veličina tržišta u smislu potencijala prodaje
 - 3.3. Komparacija s konkurencijom
 - 3.4. SWOT analiza poduzeća
4. Opis problema studije slučaja
5. Opis skupa podataka
 - 5.1. Contract data
 - 5.1.1. Osnovne informacije
 - 5.1.2. Opći opis skupa podataka
 - 5.1.3. Struktura podataka (opis atributa)
 - 5.1.4. Izvor podataka
 - 5.1.5. Ograničenja i napomene
 - 5.2. Leads data
 - 5.2.1. Osnovne informacije
 - 5.2.2. Opći opis skupa podataka
 - 5.2.3. Struktura podataka (opis atributa)
 - 5.2.4. Izvor podataka
 - 5.2.5. Ograničenja i napomene
 - 5.3. Offer data
 - 5.3.1. Osnovne informacije
 - 5.3.2. Opći opis skupa podataka
 - 5.3.3. Struktura podataka (opis atributa)
 - 5.3.4. Izvor podataka
 - 5.3.5. Ograničenja i napomene
 - 5.4. Publishing data
 - 5.4.1. Osnovne informacije
 - 5.4.2. Opći opis skupa podataka
 - 5.4.3. Struktura podataka (opis atributa)
 - 5.4.4. Izvor podataka
 - 5.4.5. Ograničenja i napomene
6. Istraživanje podataka
 - 6.1 Kategorijske varijable
 - 6.2. Numeričke varijable
 - 6.3. Odnosi između atributa
7. Provjera kvalitete podataka
 - 7.1. Nedostajuće vrijednosti
 - 7.2. Duplikati
 - 7.3. Stršila
8. Priprema podataka

- 8.1. Odabir podataka
- 8.2. Čišćenje podataka
- 8.3. Konstrukcija podataka
- 8.4. Integriranje podataka
- 8.5. Oblikovanje podataka
- 9. Modeliranje
 - 9.1. Odabir tehnike modeliranja
 - 9.2. Dizajn testiranja
 - 9.3. Izgradnja modela
 - 9.4. Procjena modela
 - 9.5. Analiza osjetljivosti
- 10. Opis kriterija i određivanja težina metodom AHP
- 11. Usporedba rezultata AHP-a i analize osjetljivosti
- 12. Vrednovanje
 - 12.1. Evaluacija rezultata
 - 12.2. Ocjenjivanje procesa
 - 12.3. Određivanje slijedećih koraka
- 13. Prijedlog i opis alternativa
- 14. Odabir najprikladnije alternative
- 15. Rizik implementacije odabrane alternative
- 16. Etička strana odabrane alternative
 - 16.1. Utjecaj na dionike
 - 16.2. Pravednost i potencijalna pristranost modela
 - 16.3. Transparentnost i odgovornost u provedbi
 - 16.4. Pregled etičkih rizika i mjera ublažavanja
- 17. Plan realizacije odabrane alternative
 - 17.1. Troškovi platformi i osnova za ROI kalkulaciju
 - 17.2. Vremenski okvir realizacije
 - 17.3. Potrebni resursi
 - 17.4. Koraci realizacije
 - 17.5. Kriteriji uspješnosti realizacije
- 18. Završna razmatranja i preporuke
- 19. Poveznica na programsko rješenje
- 20. Literatura
- 21. Prilozi
 - Popis tablica
 - Popis slika

1. Opis poduzeća

Poduzeće Emil Frey Digital društvo je s ograničenom odgovornošću sa sjedištem u Varaždinu te je dio šire Emil Frey grupacije, jedne od vodećih europskih kompanija u automobilske industriji. Osnovano je 2017. godine.

Misiju poduzeća možemo definirati kao razvoj inovativnih i kvalitetnih digitalnih rješenja koja unapređuju same poslovne procese te korisničko iskustvo u automobilske industriji.

Vizija poduzeća usmjerena je prema tome da postane vodeći digitalni i inovacijski centar unutar Emil Frey grupacije te jedan od ključnih pokretača digitalne transformacije automobilske industrije u Europi.

Ciljeve poduzeća možemo opisati kroz kontinuirani razvoj i stalno unapređenje usluga, primjenu naprednih tehnologija poput umjetne inteligencije, jačanje konkurentnosti Emil Frey grupacije na tržištu, pružanje inovativnih rješenja te ulaganje u razvoj i obrazovanje svojih zaposlenika.

2. Opis usluga

Emil Frey Digital razvija napredna softverska rješenja za automobilsku industriju s ciljem unapređenja digitalne prodaje i poslovnih procesa. Kao dio Emil Frey Grupe, poduzeće aktivno potiče digitalni razvoj i inovacije te doprinosi zadržavanju vodeće pozicije grupacije u industriji.

Poduzeće djeluje u području suvremenih tehnologija te pokriva više ključnih segmenata, uključujući razvoj web i mobilnih aplikacija, strojno učenje i umjetnu inteligenciju, automatizaciju poslovnih procesa, sustave za upravljanje odnosima s korisnicima (CRM), poslovnu inteligenciju te upravljanje podacima i integracije sustava.

Poduzeće razvija web i mobilne aplikacije namijenjene korisnicima koji koriste digitalne kanale te za interne procese, čime povezuje korisničko iskustvo s poslovnim aktivnostima

U području strojnog učenja i umjetne inteligencije poduzeće razvija i primjenjuje rješenja za analizu velikih skupova podataka te izradu prediktivnih modela koji omogućuju donošenje odluka temeljenih na podacima.

Također, razvijaju softverska rješenja za automatizaciju poslovnih procesa te unapređuju radne tokove pomoću alata iz vlastitog softverskog laboratorija.

Emil Frey Digital razvija CRM sustave za upravljanje odnosima s korisnicima koji omogućuju cjelovit uvid u podatke o korisnicima te podržavaju personaliziranu komunikaciju, segmentaciju i praćenje rezultata u stvarnom vremenu.

U sklopu svoje ponude razvijaju rješenja poslovne inteligencije koja omogućuju praćenje poslovnih performansi u stvarnom vremenu te donošenje odluka temeljenih na podacima.

Povezivanjem različitih platformi i sustava u jedinstvenu cjelinu putem sustava za upravljanje podacima i integracije poduzeće dodatno unapređuje poslovne procese te osigurava veću vrijednost za poslovanje.

3. Analiza tržišta i konkurencije

3.1. Ciljne skupine

Ciljne skupine Emil Frey Digital definirane su prema korisnicima koji sudjeluju u prodaji vozila putem digitalnih platformi. Ciljne skupine čine automobilske trgovci i auto kuće koji svoje automobile oglašavaju putem različitih digitalnih platformi. Ova ciljna skupina je najvažnija zato što uz pomoć analitičkih preporuka i rješenja pokušava unaprijediti vidljivost oglasa, cijene, ali i zainteresiranost kupaca.

U ciljnu skupinu ubrajamo krajnje korisnike, odnosno krajnje kupce automobila koji svakodnevno i aktivno pretražuju oglase i uspoređuju cijene automobila s autentičnim informacijama. Kupcima je važno da su informacije jednostavne i relevantne i da je proces same kupnje jednostavan.

Sljedeću ciljnu skupinu čine prodajni i marketinški stručnjaci koji oglašavanjem pokušavaju povećati pregled oglasa i broj kupaca, a analitičari podataka organizirano prate učinkovitost oglašavanja oglasa te generiraju daljnje preporuke za oglašavanje kako bi se poboljšao učinak uz najpovoljnije troškove.

3.2. Veličina tržišta u smislu potencijala prodaje

Tržište prodaje vozila u Europi je vrlo veliko, razvijeno i u neprestanom rastu uz potencijalnu digitalnu inovaciju i transformaciju. Prema European Automobile Manufacturers Association u 2025. godini registrirano je oko 13,3 milijuna osobnih vozila, što prikazuje porast od oko 2,4% u odnosu na prethodnu godinu u Europi (EU, UK, EFTA). Na globalnoj razini, broj prodanih vozila postiže velike brojke od oko 75 milijuna čime potvrđujemo stabilnost i tržišni potencijal automobilske industrije.

Osim veličine tržišta, važan čimbenik u smislu potencijala prodaje predstavlja ponašanje kupaca. U današnje vrijeme razvojem digitalnih kanala i medija povećala se i prodaja putem takvih kanala zbog brže i veće dostupnosti informacija i ponude. Online prodaja nije konstantna već neprestano varira zbog toga postoji potreba za njezinim poboljšanjem i optimizacijom.

S obzirom na to da je tržište veliko, relativno stabilno i u stalnom rastu postoji značajan opseg za primjenu dodatnih digitalnih rješenja. Uz pomoć progresivnih analitičkih rješenja moguće je znatno povećati učinkovitost oglašavanja, optimizacije i ostvariti što veću prodaju.

3.3. Komparacija s konkurencijom

Konkurenciju Emil Frey Digital grupacije možemo podijeliti na direktnu i indirektnu konkurenciju. Direktnu konkurenciju čine IT poduzeća koja su kao i sam Emil Frey specijalizirana za razvoj softvera i aplikacija za distribuciju i prodaju automobila. Također, direktnu konkurenciju čine automobilske kompanije i auto kuće koje koriste vlastite softvere za prodaju svojih proizvoda, odnosno automobila. Indirektnu konkurenciju čine IT kompanije koje nisu specijalizirane samo za automobilsku industriju nego posluju u više različitih područja. U nastavku će biti navedena i objašnjenje djelatnosti nekih od poduzeća koja konkuriraju Emil Frey Digital.

Porsche Digital Croatia je poduzeće koje se bavi razvojem digitalnih proizvoda za Porsche grupaciju. Digitalni proizvodi koje oni razvijaju su mobilna aplikacija za kupce, putem koje kupci mogu pratiti vozilo, te e-trgovina za opremu za Porsche automobile.

Porsche Digital predstavlja konkurenciju Emil Frey Digital-u jer posluje na području Hrvatske i djeluje kao razvojni centar za automobilske sektor. Emil Frey Digital ima prednost nad Porsche Digital-om Croatia jer nije fokusiran samo na razvoj digitalnog proizvoda jedne marke.

Incadea je primjer direktne konkurencije sa sjedištem u Europi, koja djeluje globalno, diljem svijeta. Specijalizirana je za razvoj softvera za automobilske industriju. Kompanija nudi softversko rješenje u kojem nudi usluge praćenja dostupnosti automobila putem softvera, upravljanje prodajom samih vozila, praćenje prodajnog procesa i analizu podataka o prodaji. Svoje softverske sustave prodaje auto-kućama. Time se olakšava posao auto-kuća, jer se svi procesi u prodaji automobila spajaju u jednu platformu. Incadea čini konkurenciju Emil Frey Digital-u jer radi i koristi slične vrste softverskih rješenja i sustava, te digitalizira sam proces prodaje vozila.

Nextlane je direktna konkurentna kompanija koja djeluje na području Europe i razvija softver za maloprodaju automobila. Također, u Nextlane-u su fokusirani na optimiziranje i digitalizaciju cijelog procesa prodaje i servisnog sustava. Razvijaju i CRM sustav za praćenje prodajnog procesa, marketing i komunikaciju s kupcima. Osim toga, glavni cilj im je povezivanje distributera i kupaca kroz jedinstvenu platformu, čime se olakšava sam proces prodaje i poboljšava iskustvo kupaca.

Nadalje, primjeri nekih od IT kompanija u Hrvatskoj koje čine indirektnu konkurenciju su Infinum, Infobip i Endava. Ove IT kompanije djeluju na području Hrvatske i mogu činiti konkurenciju Emil Frey Digital-u jer nude digitalne proizvode i mogu raditi na softverskim rješenjima za automobilske kompanije.

Zaključno, konkurencija Emil Frey Digital-a u Hrvatskoj je znatno slabija u odnosu na globalno tržište. U Hrvatskoj, većina IT kompanije nije specijalizirana samo za jednu djelatnost, odnosno za razvijanje softvera za automobilske industriji. Iz tog razloga Emil Frey Digital ostvaruje konkurentsku prednost na hrvatskom tržištu. Na globalnoj i europskoj razini konkurencija je velika. Sam razlog tome je postojanje velikog broja automobilske kompanije koje razvijaju svoje softvere. Također, na globalnom tržištu postoji konkurencija koja se bavi sličnom ili istom djelatnošću, odnosno razvojem softvera za prodaju i distribuciju automobila.

3.4. SWOT analiza poduzeća

Snage

Stabilan rast prihoda i dobiti, koji označava porast prihoda s 7,3 mil.€ u 2022. na 11,9 mil.€ u 2024.

Visoka bonitetna ocjena AA+ ukazuje na nisku razinu rizika i financijsku stabilnost.

Emil Frey Digital ima zdravu financijsku strukturu što znači da je likvidno, ima uredno poslovanje i nema poreznih dugova.

Podrška velike grupacije Emil Frey Automobili koja je jaka korporativna podrška i ima stabilno tržište.

Slabosti

Ovisnost o jednoj grupaciji znači manju autonomiju i ovisnost o strategiji grupe.

Pad kapitala u 2024. godini uzrokovao mogući financijski pritisak.

Geografska koncentracija orijentirana je na Varaždin što nije baš najbolje zato što bi veće tržište pružilo veću mogućnost zarade.

Prilike

Digitalizacija auto-industrije omogućuje online prodaje što je u današnje vrijeme vrlo praktično i vrlo prilagođeno današnjem vremenu. Rast IT sektora omogućuje razvoj novih proizvoda i inovacija koje druge tvrtke nemaju što omogućuje privlačenje novih klijenata što dovodi do širenja tržišta.

Prijetnje

Pad prodaje vozila utječe na potrebu za IT rješenjima.

Proizvođači automobila sve više prelaze na direktnu prodaju što smanjuje ulogu distributera i potreba za IT rješenjima.

Emil Frey Digital nije jak brend na otvorenom tržištu stoga teže privlači klijente izvan grupacije.

4. Opis problema studije slučaja

Na trenutnom tržištu digitalne prodaje automobile postoji veliki broj različitih oglašivačkih kanala i platformi. Troškovi objava su visoki, a posebice ako se automobil oglašava na više platformi. Zbog širokog spektra kupaca i tipova platformi postoje razlike u kvalitetama upita. Iako se dobiva velik broj pregleda oglasa i upita (leadova), glavni problem je niska konverzija u stvarnu prodaju.

Glavno pitanje koje se javlja u studiji slučaja je: "Na kojim oglašivačkim platformama se vozilo stvarno isplati oglašavati?" Izazovi do kojih se dolazi proizlaze iz toga što uspjeh prodaje ovisi o puno faktora: brendu, modelu, cijeni, regiji, oglasniku i tipu vozila (npr. je li to SUV, premium ili mali gradski auto). Te izazove se najbolje vidi kroz različite kategorije automobila:

- Premium vozila: Na općim oglasnicima privlače puno pažnje, ali većina upita dolazi od ljudi koji nisu u tom cjenovnom razredu. Na portalima s filtriranim kupcima upita je manje, ali je konverzija puno veća.
- Mali gradski automobili: Oni zahtijevaju veliku vidljivost koju pružaju masovni oglasnici, dok na specijaliziranim portalima često prolaze nezapaženo jer ih kupci tamo ne traže.
- Električni automobili: Na generalnim portalima generiraju puno znatizeljnih klikova bez prave namjere kupnje, dok tech-orijentirane platforme privlače kupce koji već imaju jasan interes za tu tehnologiju.

Cilj studija slučaja je primijeniti „data-driven decision making“ odnosno donošenje odluka koje se temelje isključivo na stvarnim podacima. Kroz analizu i povezivanje dobivenih podataka te izračun ključnih metrika, želimo prepoznati trendove koji će nam pomoći u optimizaciji strategije oglašavanja prema cjenovnim segmentima i tipovima vozila. Krajnji cilj je donošenje boljih odluka o tome gdje, kako i koliko oglašavati vozila kako bismo postigli prodaju uz što manje troškove oglašavanja.

5. Opis skupa podataka

5.1. Contract data

5.1.1. Osnovne informacije

Naziv skupa podataka: FOI_contract_data.csv

Autor / Organizacija: Emil Frey Digital

Format podataka: CSV

5.1.2. Opći opis skupa podataka

Skup podataka sadrži informacije o ugovorima povezanim s vozilima i ponudama u sustavu. Podaci uključuju identifikatore ugovora, vozila i ponuda, datume kreiranja i zadnje izmjene ugovora te status ugovora.

5.1.3. Struktura podataka (opis atributa)

Naziv atributa	Tip podatka	Opis	Primjer vrijednosti
CONTRACT_ID	INT	Jedinstveni identifikator ugovora	1
VEHICLE_ID	INT	Identifikator vozila na koje se ugovor odnosi	1
OFFER_ID	INT	Identifikator ponude povezane s ugovorom	1
CONTRACT_DATE_CREATED	DATETIME	Datum i vrijeme kada je ugovor kreiran	2025-12-15 15:05:19.278
CONTRACT_LAST_MODIFIED	DATETIME	Datum i vrijeme zadnje izmjene ugovora	2025-12-15 15:05:19.278
CONTRACT_STATUS	VARCHAR	Trenutni status ugovora	Canceled

Tablica 1. Struktura podataka contract data

5.1.4. Izvor podataka

Podaci su generirani unutar informacijskog sustava za upravljanje vozilima, ponudama i ugovorima.

5.1.5. Ograničenja i napomene

Neki podaci mogu imati nedostajuću vrijednost u stupcu OFFER_ID (NaN), što znači da za vozilo nije data ponuda, a postoji ugovor.

Stupac CONTRACT_STATUS može sadržavati sljedeće vrijednosti:

Status	Opis
Canceled	Ponuda ili ugovor su otkazani od strane kupca
Invoiced	Izdan je račun za ugovor
Storno	Ugovor je storniran od vanjskog sustava
Countersigned	Ugovor je potpisan od strane auto kuće (od obje strane)
Pending	Ponuda ili ugovor su kreirani i čekaju daljnu akciju
Accepted	Ugovor je prihvaćen od drugog sustava za izradu računa
Importing_error	Došlo je do greške prilikom uvoza ugovora u drugi sustav
Signed	Kupac je potpisao ugovor

Tablica 2. Moguće vrijednosti stupca *CONTRACT_STATUS*

5.2. Leads data

5.2.1. Osnovne informacije

Naziv skupa podataka: *FOI_leads_data.csv*

Autor / Organizacija: Emil Frey Digital

Format podataka: CSV

5.2.2. Opći opis skupa podataka

Skup podataka predstavlja evidenciju leadova generiranih putem različitih online marketplace platformi (npr. VehicleHub, AutoTradeNet, CarFinder). Svaki zapis predstavlja jedan lead povezan s određenim vozilom.

Podaci omogućuju:

- praćenje interesa potencijalnih kupaca za vozila
- analizu izvora leadova (marketplace platformi)
- praćenje statusa komunikacije s klijentima
- analizu vremena zatvaranja leadova

5.2.3. Struktura podataka (opis atributa)

Naziv atributa	Tip podatka	Opis	Primjer vrijednosti
LEAD_ID	INT	Jedinstveni identifikator leada	1
VEHICLE_ID	INT	Identifikator vozila na koje se lead odnosi	1

MARKETPLACE	VARCHAR	Naziv marketplace platforme s koje je lead generiran	AutoTradeNet
LEAD_DATE_CREATED	DATETIME	Datum i vrijeme kada je lead kreiran	2025-12-15 15:05:19.278
LEAD_STATUS	VARCHAR	Trenutni status leada	contacted
LEAD_CLOSING_DATE	DATETIME	Datum i vrijeme zatvaranja leada	2025-12-15 15:05:19.278

Tablica 3. Struktura podataka leads data

5.2.4. Izvor podataka

Podaci dolaze iz različitih online marketplace platformi koje omogućuju potencijalnim kupcima da pokažu interes za vozila.

Primjeri marketplace platformi:

- VehicleHub
- AutoTradeNet
- CarFinder

5.2.5. Ograničenja i napomene

Jedan vehicle_id može imati više leadova jer više kupaca može biti zainteresirano za isto vozilo. Vrijeme zatvaranja leada (LEAD_CLOSING_DATE) označava trenutak kada je proces komunikacije s leadom završen. Status leada može se mijenjati tijekom procesa prodaje.

Stupac LEAD_STATUS može sadržavati sljedeće vrijednosti:

Status	Opis
contacted	Kupac je kontaktiran od strane prodajnog zaposlenika
disqualified	Lead je procijenjen kao nedovoljna za autokuću i neće se dalje obrađivati
follow_up	Potrebna je dodatna komunikacija ili praćenje kupca
manager_lead_pool	Lead je dostupan u poolu za manager zaposlenike u auto kući koji ga mogu preuzeti
dealer_lead_pool	Lead je dostupan u poolu za zaposlenike u auto kući koji ga mogu preuzeti
won	Lead je uspješno konvertiran u prodaju
allocated	Lead je dodijeljen konkretnom zaposleniku u auto kući
offer	Kupcu je poslana ponuda
contract	Kupcu je kreiran ugovor

Tablica 4. Moguće vrijednosti stupca LEAD_STATUS

5.3. Offer data

5.3.1. Osnovne informacije

Naziv skupa podataka: FOI_offer_data.csv

Autor / Organizacija: Emil Frey Digital

Format podataka: CSV

5.3.2. Opći opis skupa podataka

Ovaj skup podataka predstavlja evidenciju ponuda koje su generirane za potencijalne kupce. Ponude su povezane s leadovima i vozilima te omogućuju praćenje procesa prodaje od inicijalnog interesa kupca do završetka ponude.

Dataset se može koristiti za:

- praćenje statusa ponuda
- analizu prodajnog procesa
- povezivanje leadova s ponudama
- praćenje trajanja i izmjena ponuda

5.3.3. Struktura podataka (opis atributa)

Naziv atributa	Tip podatka	Opis	Primjer vrijednosti
OFFER_ID	INT	Jedinstveni identifikator ponude	1
VEHICLE_ID	INT	Identifikator vozila na koje se ponuda odnosi	1
LEAD_ID	INT	Identifikator leada povezanog s ponudom	1
OFFER_DATE_CREATED	DATETIME	Datum i vrijeme kada je ponuda kreirana	2025-12-15 15:05:19.278
OFFER_LAST_MODIFIED	DATETIME	Datum i vrijeme zadnje izmjene ponude	2025-12-15 15:05:19.278
OFFER_STATUS	VARCHAR	Status ponude	completed

Tablica 5. Struktura podataka offer data

5.3.4. Izvor podataka

Podaci su generirani unutar prodajnog sustava za upravljanje leadovima, ponudama i prodajom vozila.

5.3.5. Ograničenja i napomene

Jedan lead može imati više ponuda. Svaka ponuda je povezana s određenim vozilom. Status ponude može se mijenjati tijekom prodajnog procesa.

Stupac OFFER_STATUS može sadržavati sljedeće vrijednosti:

Status	Opis
expired	Ponuda je istekla
completed	Proces prodaje je završen
canceled	Ponuda ili ugovor su otkazani od strane kupca
pending	Ponuda ili ugovor su kreirani i čekaju daljnu akciju

Tablica 6. Moguće vrijednosti stupca OFFER_STATUS

5.4. Publishing data

5.4.1. Osnovne informacije

Naziv skupa podataka: FOI_publishing_data.csv

Autor / Organizacija: Emil Frey Digital

Format podataka: CSV

5.4.2. Opći opis skupa podataka

Ovaj skup podataka prati proces objavljivanja vozila na online marketplace platformama. Svaki zapis predstavlja jedno vozilo koje je objavljeno ili pripremljeno za objavu na određenoj platformi.

Dataset omogućuje:

- praćenje gdje su vozila objavljena
- praćenje statusa objave vozila
- analizu tehničkih karakteristika vozila
- analizu cijena i kilometraže vozila

5.4.3. Struktura podataka (opis atributa)

Naziv atributa	Tip podatka	Opis	Primjer vrijednosti
VEHICLE_ID	INT	Jedinstveni identifikator vozila	1
MARKETPLACE	VARCHAR	Naziv marketplace platforme na kojoj se vozilo objavljuje	VehicleHub
PUBLISH_STATUS	VARCHAR	Status objave vozila	Published
DATE_START	DATETIME	Datum i vrijeme početka objave	2025-12-15 15:05:19.278
DATE_END	DATETIME	Datum i vrijeme završetka objave	2025-12-15 15:05:19.278
BRAND	VARCHAR	Marka vozila	VOLVO
MODEL	VARCHAR	Model vozila	C40
MODEL_VERSION	VARCHAR	Specifična verzija modela vozila	NX 450h+ F-Sport
BODY_TYPE	VARCHAR	Tip karoserije vozila (npr. Saloon, SUV, MPV)	Saloon
TRANSMISSION	VARCHAR	Tip mjenjača (npr. Manual, CVT, Semi-automatic)	Semi-auto.
DRIVE_TYPE	VARCHAR	Tip pogona (npr. All-wheel, Front-wheel)	All-wheel
FUEL_TYPE	VARCHAR	Vrsta goriva ili pogonskog sustava (npr. Petrol, Electric, Hybrid)	Electric
CO2_EMISSION	FLOAT	Emisija CO ₂ vozila	25.0
PRODUCTION_YEAR	INT	Godina proizvodnje vozila	2023.0
CURRENT_MILEAGE	FLOAT	Trenutna kilometraža vozila	8800.0
PRICE	FLOAT	Cijena vozila	38500.0

Tablica 7. Struktura podataka publishing data

5.4.4. Izvor podataka

Podaci dolaze iz sustava za upravljanje prodajom vozila koji objavljuje vozila na različitim marketplace platformama kao što su:

- AutoTradeNet
- VehicleHub
- AutoMarket

5.4.5. Ograničenja i napomene

Jedno vozilo može biti objavljeno na više marketplace platformi. Status objave može se mijenjati tijekom vremena.

Cijena i kilometraža predstavljaju trenutno stanje vozila u trenutku objave.

Stupac PUBLISH_STATUS može sadržavati sljedeće vrijednosti:

Status	Opis
Unpublished	Vozilo nije objavljeno na marketplace platformi ili je uklonjeno iz objave.
Active	Vozilo je trenutno aktivno objavljeno na marketplace platformi i vidljivo potencijalnim kupcima.
Deactivated	Objavljeni oglas za vozilo je deaktiviran, što znači da više nije aktivan, ali je prethodno bio objavljen.

Tablica 8. Moguće vrijednosti stupca PUBLISH_STATUS


6. Istraživanje podataka

6.1 Kategorijske varijable

Analiza kategorijskih varijabli provedena je posebno za svaki izvor podataka, kako bi se dobio uvid u svaki od njih. Skupovi podataka `contract_data`, `leads_data` i `offer_data` sadrže mali broj kategorijskih varijabli. Kod skupa `contract_data` posebno se ističe, i posebno je važna u kontekstu problema, varijabla `CONTRACT_STATUS` s osam različitih kategorija što upućuje na mogućnost više različitih ishoda ugovaranja. Vizualizacijom distribucije ove varijable uočava se da kategorija `invoiced` značajno prednjači po broju ponavljanja što ukazuje na velik broj uspješno realiziranih ugovora i predstavlja važan signal za daljnju analizu uspješnosti oglasa.

	Varijabla	Broj kategorija
1	CONTRACT_DATE_CREATED	79098
2	CONTRACT_LAST_MODIFIED	75758
3	CONTRACT_STATUS	8

Tablica 9. *Contract_data*



Slika 1: Prikaz distribucije statusa ugovora

U skupu offer_data varijabla OFFER_STATUS sadrži četiri kategorije, dok u skupu leads_data varijabla LEAD_STATUS sadrži devet kategorija što također upućuje na različite faze obrade ponuda i leadova.

	Varijabla	Broj kategorija
1	OFFER_DATE_CREATED	191494
2	OFFER_LAST_MODIFIED	190665
3	OFFER_STATUS	4

Tablica 10. Offer_data

	Varijabla	Broj kategorija
1	MARKETPLACE	4
2	LEAD_DATE_CREATED	35552
3	LEAD_STATUS	9
4	LEAD_CLOSING_DATE	29858

Tablica 11. Leads_data


U skupu publishing_data pojavljuje se puno više kategorijskih varijabli s različitim brojem kategorija. Posebno se ističu BRAND, MODEL i MODEL_VERSION koje imaju velik broj jedinstvenih kategorija što bi moglo zahtijevati naknadno grupiranje kako bi se omogućila lakša obrada i modeliranje tih podataka.

	Varijabla	Broj kategorija
1	MARKETPLACE	4
2	PUBLISH_STATUS	3
3	DATE_START	360482
4	DATE_END	360482

5	BRAND	111
6	MODEL	1336
7	MODEL_VERSION	56760
8	BODY_TYPE	39
9	TRANSMISSION	22
10	DRIVE_TYPE	10
11	FUEL_TYPE	34

Tablica 12. Publishing_data

Uzimajući u obzir ciljeve rudarenja podataka, posebno je stavljen fokus na varijablu MARKETPLACE s obzirom na to da je oglašivačka platforma ključan element poslovnog problema. Vizualizacija distribucije varijable MARKETPLACE prikazuje da najveći broj oglasa dolazi s platforme VehicleHub što ukazuje na njenu dominaciju u odnosu na ostale platforme u ovom skupu podataka.



Slika 2: Distribucija varijable MARKETPLACE


6.2. Numeričke varijable

Analiza numeričkih varijabli provedena je primarno na skupu podataka publishing_data s obzirom na to da ostali skupovi od numeričkih podataka sadrže samo identifikacijske attribute koji sami po sebi nisu relevantni za analizu i procjenu uspješnosti zbog čega nisu dodatno interpretirani. Osnovna statistička analiza skupa publishing_data prikazana je u tablici 5.


	count	mean	std	min	25%	50%	75%	max
VEHICLE_ID	1513937.0	3.522143e+06	572641.137417	80698.0	3205356.0	3635185.0	3916249.0	4210271.0
CO2_EMISSION	1451353.0	1.150416e+02	77.737114	0.0	38.0	130.0	163.0	1400.0
PRODUCTION_YEAR	1373273.0	2.022349e+03	15.138138	6.0	2022.0	2023.0	2024.0	2027.0
CURRENT_MILEAGE	1512932.0	2.023582e+04	106217.808921	0.0	21.0	6000.0	26558.0	99999999.0
PRICE	1513897.0	4.702877e+04	330747.675325	-656700.0	26550.0	38900.0	56290.0	99999999.0

Tablica 13. Statistička analiza numeričkih varijabli


Proučavanjem vrijednosti u prethodnoj tablici može se zaključiti da skup podataka pretežno obuhvaća novija vozila s obzirom na to da je medijan 2023. godina. Varijabla CURRENT_MILEAGE prikazuje veliku raspršenost podataka pri čemu su uočene i ekstremno visoke vrijednosti. Ekstremne vrijednosti također su uočene i kod varijable PRICE. Osim tih vrijednosti, vidljive su nelogične negativne vrijednosti što upućuje na potrebu za dodatnim čišćenjem ovih podataka. Na slikama ispod, prikazana je vizualizacija navedenih varijabli provedena s ciljem lakšeg shvaćanja i interpretacije.



Slika 3: Distribucija varijable PRICE



Slika 4: Distribucija varijable *PRODUCTION_YEAR*




Slika 5: Distribucija varijable *CURRENT_MILEAGE*

6.3. Odnosi između atributa

U skupu publishing_data posebno je analiziran odnos između cijene i kilometraže vozila, što je prikazano na slici 6. Na grafu je uočena očekivana negativna povezanost, odnosno vozila s većom kilometražom u pravilu imaju nižu cijenu.

Ovakav odnos potvrđuje pouzdanost i logičnost podataka, s obzirom na to da se poklapa s realnim stanjem na tržištu. Dokazivanje pouzdanosti podataka bitno je za daljnju analizu uspješnosti oglasa i odabira optimalne oglašivačke platforme.



Slika 6: Odnos između cijene i kilometraže

7. Provjera kvalitete podataka

7.1. Nedostajuće vrijednosti

Nedostajuće vrijednosti analizirane su za sve skupove podataka korištenjem funkcija `isna()`, `sum()`, `imean()*100`, čime je određen broj i postotak nedostajućih vrijednosti po atributima.

U skupu `contract_data` nedostajuće vrijednosti pojavljuju se isključivo kod varijable `OFFER_ID` gdje je broj nedostajućih zapisa 39003 odnosno 49,30%. Iako je broj velik, ovakav rezultat je očekivan jer ugovori nisu nužno povezani s ponudama što upućuje na to da se radi o realnom poslovnom procesu, a ne pogrešci u podacima.

Skupovi `offer_data` i `leads_data` ne sadrže nedostajuće vrijednosti iz čega se može zaključiti da su podaci konzistentni i pouzdani.

Nedostajuće vrijednosti u skupu `publishing_data` prikazane su u tablici ispod. Najveći nedostatak uočen je kod varijabli `PRODUCTION_YEAR` i `CO2_EMISSION`, dok je kod ostalih varijabli zanemariv broj nedostajućih vrijednosti.

	Broj nedostajućih	Postotak
PRODUCTION_YEAR	140664	9.291272
CO2_EMISSION	62584	4.133858
CURRENT_MILEAGE	1005	0.066383
PRICE	40	0.002642
MODEL_VERSION	3	0.000198

Tablica 14. Nedostajuće vrijednosti po varijablama

7.2. Duplikati


Provjera duplikata provedena je za sve skupove podataka korištenjem funkcije `duplicated()`. Analizom nije utvrđeno postojanje duplikata niti u jednom od promatranih skupova podataka, što je potvrda dobre kvalitete i konzistentnosti podataka.

7.3. Stršila


Analizom numeričkih varijabli uočena su značajna odstupanja (stršila), posebice kod varijabli cijene i kilometraže. Uočene su ekstremno visoke i niske vrijednosti koje odstupaju od realnih tržišnih uvjeta. Primjer za to su izuzetno visoke i nerealne cijene i kilometraže.

Takva odstupanja mogu negativno utjecati na obradu podataka i kasnije modeliranje, zbog čega ih je potrebno dodatno obraditi u fazi čišćenja primjenom metoda filtriranja i uklanjanja nelogičnih vrijednosti.


Stršila su vizualno prikazana na sljedećim slikama.




Slika 7: Prikaz stršila za varijablu CO2_EMISSION



Slika 8: Prikaz stršila za varijablu CURRENT_MILEAGE



Slika 9: Prikaz stršila za varijablu PRICE



Slika 10: Prikaz stršila za varijablu PRODUCTION_YEAR

8. Priprema podataka

8.1. Odabir podataka

U postupku odabira podataka zadržani su svi atributi iz izvornog skupa podataka s obzirom na to da su svi relevantni za analizu uspješnosti oglasa. Unatoč tome što identifikacijski atributi nisu potrebni za analizu, privremeno su zadržani zbog potrebe za integracijom podataka iz više skupova gdje su korišteni kao vanjski ključevi. Nakon završetka procesa integracije, navedeni atributi su uklonjeni iz konačnog skupa podataka.

Iz skupa podataka `contract_data` isključeni su zapisi s vrijednostima „importing_error“ i „pending“ u varijabli `CONTRACT_STATUS`. Navedene kategorije ne pružaju informaciju o uspješnosti ugovora, koja je potrebna kako bi se analiza mogla provesti, te su zbog toga isključene iz daljnje obrade.

8.2. Čišćenje podataka

Prvi korak u fazi čišćenja podataka bio je ujednačavanje kategorijskih vrijednosti. U skupu `leads_data` vrijednosti varijable `LEAD_STATUS` grupirane su u zajedničke kategorije („contract“ u „won“, „manager_lead_pool“ i „dealer_lead_pool“ u „pool“, „offer“ u „contacted“), a u skupu `offer_data` vrijednost „expired“ je zamijenjena s „canceled“. Cilj ovoga bio je smanjenje broja različitih kategorija i povećanje konzistentnosti podataka.


U skupu podataka uočene su nelogične vrijednosti, poput vrijednosti za varijablu `PRODUCTION_YEAR` koje su manje ili jednake 1886. godini. Osim što je nelogična prodaja toliko starih auta, činjenica da je pojava prvog auta 1886. dodatno pojačava nelogičnost tih vrijednosti. Nelogične vrijednosti su se pojavljivale i kod varijable `PRICE`. Recimo neke varijable su bile unutar realnog raspona cijena, ali su negativne, čime zaključujemo da je moguće da su rezultat pogreške. Takve vrijednosti su pretvorene u apsolutne vrijednosti, dok su ostale (one koje nisu u realnom rasponu) postavljene ne nedostajuće vrijednosti. Još jedna nelogična vrijednost bila je vrijednost 0 kod varijable `CURRENT_MILEAGE`. Ta vrijednost je također zamijenjena nedostajućom vrijednošću s obzirom na to da ne predstavlja realno moguće stanje vozila.

Provedeno je grupiranje kategorijskih varijabli, poput `FUEL_TYPE`, `BRAND`, `DRIVE_TYPE` i `TRANSMISSION` kako bi se izjednačile različite pojave istih kategorija i smanjilo njihovo ponavljanje.


Nedostajuće vrijednosti su popunjene korištenjem statistike. Za varijablu `MODEL_VERSION` korištena je najčešća vrijednost unutar pojedinog modela. Numeričke varijable poput `CO2_EMISSION`, `PRODUCTION_YEAR`, `PRICE` i `CURRENT_MILEAGE` popunjene su sa srednjim vrijednostima unutar odgovarajućih relevantnih grupa (npr. prema modelu, marki...).

Kako bi se riješio problem stršila, vrijednosti cijena su filtrirane izvan realnog raspona koji je određen na 1000-80000. Nakon toga je za svako vozilo izračunat omjer cijene u odnosu na medijan cijene unutar iste kombinacije marke i modela. Vrijednosti koje su zadržane su samo one koje su unutar definiranog raspona omjera te su se time uklonile ekstremne vrijednosti.


Sličan način je primijenjen i na varijablu `CURRENT_MILEAGE` gdje je izračunat omjer kilometraže u odnosu na medijan unutar kombinacije marke, modela i godine proizvodnje, čime su se uklonile vrijednosti koje odstupaju od realnih podataka. Dodatno je uvedeno pravilo kojim se definira maksimalna očekivana kilometraža koja ovisi o starosti vozila. Gornja granica je postavljena an 400000 te su time uklonjene dodatne nelogičnosti.




Slika 11: Box plot dijagram za prikaz CO2_EMISSION



Slika 12: Box plot dijagram za prikaz CURRENT_MILEAGE



Slika 13: Box plot dijagram za prikaz PRICE



Slika 14: Box plot dijagram za prikaz PRODUCTION_YEAR

8.3. Konstrukcija podataka

U ovom koraku provedena je transformacija postojećih atributa i generirani su nove varijable s ciljem poboljšanja kvalitete podataka i kvalitete budućeg modela.

U skupu podataka `contract_data`, za varijablu `CONTRACT_STATUS` definirani su željeni statusi ugovora. Nakon toga varijabla je transformirana u binarnu varijablu u kojoj vrijednost 1 označava uspješno realizirane ugovore ('invoiced', 'countersigned', 'accepted', 'signed'), dok 0 označava ostale statuse. Konstruirana je nova varijabla `CONTRACT_MODIFICATION_DURATION` koja predstavlja vremensku razliku između datuma kreiranja ugovora i zadnje izmjene ugovora. Varijabla je izražena u broju dana čime je omogućeno određivanje trajanja procesa ugovaranja. S obzirom na to da vrijeme trajanja procesa može biti pod utjecajem neradnih dana, kreirane su dodatne varijable `CONTRACT_DATE_CREATED_IS_WEEKEND` i `CONTRACT_LAST_MODIFIED_IS_WEEKEND` koje označavaju je li događaj nastao tijekom vikenda.

Istim postupkom konstruirani su i atributi u skupovima podataka `leads_data`, `offer_data` i `publishing_data` kako bi se osigurala konzistentnost u obradi svih izvora podataka.

Osim navedenog, kreirana je i varijabla `AGE` koja predstavlja starost vozila i izračunata je kao razlika trenutne godine i godine proizvodnje vozila. Konstrukcija ove varijable omogućuje precizniju analizu kilometraže vozila, s obzirom na to da kilometraža ovisi o starosti vozila.

8.4. Integriranje podataka

Kao osnovni skup za integraciju korišten je skup `published_data` (odnosno njegov očišćeni oblik `df_clean`) koji sadrži informacije o oglasima vozila. Na navedeni skup integrirani su dodatni izvori podataka koji su prethodno očišćeni.

Najprije je izvršeno integriranje sa skupom `contract_data` korištenjem atributa `VEHICLE_ID` kao zajedničkog ključa. Nakon toga skup je proširen podacima iz skupa `offer_data` pomoću atributa `OFFER_ID`. Korištenjem atributa `LEAD_ID`, prethodno integrirani podaci su povezani sa skupom `leads_data`, čime je formiran konačan skup podataka.

Prilikom spajanja korišten je tip spajanja `left join` čime je osigurano da se u podacima zadrže svi zapisi iz početnog skupa podataka (odnosno svi oglasi), bez obzira na to imaju li leadove, ponude i ugovore. Ovaj korak omogućuje analizu kako uspješnih, tako i neuspješnih oglasa.

Tablica podataka nakon njihove integracije izgleda ovako:

	Naziv stupca	Broj unosa	Tip podatka
1	MARKETPLACE	932768	object
2	PUBLISH_STATUS	932768	object
3	DATE_START	932768	datetime64[ns]
4	BRAND	932768	object
5	MODEL	932768	object
6	MODEL_VERSION	932768	object
7	BODY_TYPE	932768	object
8	TRANSMISSION	932768	object
9	DRIVE_TYPE	932768	object

10	FUEL_TYPE	932768	object
11	CO2_EMISSION	932768	float64
12	PRODUCTION_YEAR	932768	float64
13	CURRENT_MILEAGE	932768	float64
14	PRICE	932768	float64
15	DURATION	932768	int64
16	DATE_START_IS_WEEKEND	932768	int64
17	DATE_END_IS_WEEKEND	932768	int64
18	AGE	932768	float64
19	CONTRACT_LAST_MODIFIED	552019	datetime64[ns]
20	CONTRACT_STATUS	552019	float64
21	CONTRACT_MODIFICATION_DURATION	552019	float64
22	CONTRACT_DATE_CREATED_IS_WEEKEND	552019	float64
23	CONTRACT_LAST_MODIFIED_IS_WEEKEND	552019	float64
24	OFFER_LAST_MODIFIED	302549	datetime64[ns]
25	OFFER_STATUS	302549	object
26	OFFER_DURATION	302549	float64
27	OFFER_DATE_CREATED_IS_WEEKEND	302549	float64
28	OFFER_LAST_MODIFIED_IS_WEEKEND	302549	float64
29	LEAD_STATUS	17195	object
30	LEAD_CLOSING_DATE	17195	datetime64[ns]
31	LEAD_DURATION	17195	float64
32	LEAD_DATE_CREATED_IS_WEEKEND	17195	float64
33	LEAD_CLOSING_DATE_IS_WEEKEND	17195	float64

Tablica 15. Stupci nakon integracije

8.5. Oblikovanje podataka

U ovoj fazi promijenjen je format atributa CONTRACT_DATE_CREATED i CONTRACT_LAST_MODIFIED u odgovarajući datetime format kako bi se omogućila njihova lakša obrada.

Osim promjene formata, provelo se kodiranje kategorijskih varijabli. Varijable MARKETPLACE, PUBLISH_STATUS, TRANSMISSION, DRIVE_TYPE, FUEL_TYPE, OFFER_STATUS i LEAD_STATUS kodirane su primjenom one-hot encodinga. Svaka kategorija je pretvorena u zasebnu binarnu varijablu čime će modelu biti omogućeno pravilno interpretiranje kategorijskih varijabli. Ova metoda je odabrana jer navedene varijable imaju relativno mali broj različitih kategorija vrijednosti te ne utječu znatno na povećanje stupaca u skupu podataka.

Metoda frequency encoding je primijenjena na varijable BRAND, MODEL, MODEL_VERSION i BODY_TYPE jer su to kategorijske varijable s velikim brojem različitih vrijednosti. Za svaku kategoriju je izračunata učestalost pojavljivanja u skupu koja je zatim mapirana natrag u izvorni skup podataka. Ova tehnika odabrana je kako bi se izbjeglo stvaranje velikog broja novih varijabli koje bi nastale u slučaju korištenja one-hot encodinga.

9. Modeliranje

9.1. Odabir tehnike modeliranja

Uzimajući u obzir cilj projekta, kao ciljna varijabla definiran je status ugovora (CONTRACT_STATUS). Statusi koji označavaju uspješno zaključen proces prodaje grupirani su u jednu klasu, dok su svi ostali statusi svrstani u drugu klasu. Cilj modela je predvidjeti hoće li oglas vozila rezultirati sklapanjem ugovora. Pri tome vrijednost CONTRACT_STATUS = 1 označava uspješno zaključen ugovor i prodano vozilo, dok CONTRACT_STATUS = 0 označava nepostojanje ugovora ili situaciju u kojoj proces prodaje nije uspješno dovršen.

Za izgradnju modela izabrane su dvije tehnike strojnog učenja - Random Forest i XGBoost. Obje metode prikladne su za rad s ovakvim skupovima podataka koji sadrže i numeričke i kategorijske varijable, kao i za modeliranje složenih nelinearnih odnosa između varijabli.

Random Forest je odabran kao osnovni model koji je početno treniran i testiran. Prednost ove metode je manja osjetljivost na outliere što je posebno važno s obzirom na heterogenost podataka o vozilima koji sadržavaju različite brendove, cjenovne razrede i sl. Kao drugi odabrani model korišten je XGBoost koji je uključen u analizu i njegovi rezultati su uspoređeni s prethodno implementiranim Random Forest modelom. XGBoost je odabran kao naprednija metoda koja često postiže vrlo dobre rezultate.

Cilj je razviti oba modela na istim podacima i nakon toga usporediti njihove rezultate koristeći odgovarajuće metrike. Model koji je ostvario bolje performanse odabran je kao konačni model za daljnju optimizaciju.

9.2. Dizajn testiranja

Kako bi se procijenila uspješnost modela, skup podataka je podijeljen na skup za treniranje i skup za testiranje. Podaci su podijeljeni u omjeru 80:20, od koji je 80% podataka korišteno za treniranje, a 20% za testiranje modela i procjenu njegovih performansi. Nakon podjele skupa, skup za treniranje sadrži ~662 000 zapisa, a skup za testiranje ~165 000 zapisa.

Za usporedbu različitih modela korišten je isti skup za treniranje i testiranje kako bi se osigurala usporedivost dobivenih rezultata. Performanse modela su procijenjene korištenjem više evaluacijskih metrika prikladnih za ovaj tip problema. S obzirom na to da sama točnost ne daje potpunu sliku ukupne uspješnosti modela, korištene su i metrike Precision, Recall, F-1 score kao i matrice zabune.

Precision predstavlja udio ispravno klasificiranih pozitivnih ugovora među svim primjerima koje je model predvidio kao uspješne. Recall mjeri udio stvarno pozitivnih primjera koje je model uspješno identificirao. F1-score predstavlja sredinu između precision i recall i pruža mjeru uspješnosti modela. Dodatno korištene matrice zabune prikazuju broj točno i netočno klasificiranih primjera za svaku klasu što omogućuje detaljan uvid u vrste pogrešaka koje model radi.

Na temelju navedenih metrika provedena je usporedba modela Random Forest i XGBoost i odabran je model s najboljim ukupnim performansama za daljnju optimizaciju hiperparametara.

Kako bi se spriječilo curenje podataka iz skupa značajki izbačene su sve varijable koji bi modelu dale informacije o ishodu koji se predviđa, a koje u stvarnom scenariju primjene ne bi bile dostupne u trenutku objave oglasa. Izbačene su sljedeće grupe varijabli:

- varijable vezane uz ugovor: CONTRACT_MODIFICATION_DURATION, CONTRACT_DATE_CREATED_IS_WEEKEND, CONTRACT_LAST_MODIFIED_IS_WEEKEND

- varijable vezane uz ponudu: OFFER_DURATION, OFFER_STATUS, OFFER_DATE_CREATED_IS_WEEKEND, OFFER_LAST_MODIFIED_IS_WEEKEND
- varijable vezane uz lead: LEAD_DURATION, LEAD_DATE_CREATED_IS_WEEKEND, LEAD_CLOSING_DATE_IS_WEEKEND
- status objave: PUBLISH_STATUS

9.3. Izgradnja modela

Za izgradnju modela korišteno je 28 ulaznih značajki. One uključuju numeričke značajke koje direktno opisuju svojstva vozila poput CO2_EMISSION, CURRENT_MILEAGE i AGE. Kategorijske značajke kodirane su one-hot encodingom u binarne stupce. To su varijable poput TRANSMISSION, DRIVE_TYPE, FUEL_TYPE i MARKETPLACE. Frequency-encoded značajke su značajke koje su kodirane relativnom frekvencijom pojavljivanja u skupu podataka i uključuju varijable poput BRAND_FREQ, MODEL_FREQ, MODEL_VERSION_FREQ i BODY_TYPE_FREQ.

Faza izgradnje modela obuhvatila je implementaciju Random Forest i XGBoost modela koji su trenirani na istom skupu podataka. Prvi implementirani model bio je Random Forest. Incijalni model koristio je 50 stabala odlučivanja uz ograničenje maksimalne dubine stabla na 15 i minimalno 50 uzoraka u svakom listu. Ovo je uvedeno kako bi se smanjila složenost modela i kako bismo izbjegli pretreniranost. Drugi implementirani model je XGBoost koji koristi 100 stabala s maksimalnom dubinom 6 i stopom učenja 0,1. Za evaluacijsku metriku tijekom treniranja korišten je logloss.

Nakon treniranja oba modela uspoređene su njihove performanse. Random Forest je pokazao nešto bolje rezultate u metrikama zbog čega je odabran kao finalni model koji će se dalje optimizirati kako bi se dobili još bolji rezultati. Ključna poboljšanja u odnosu na prvi Random Forest model je povećanje broja stabala na 100 i dodavanje parametra `class_weight='balanced'` kako bi se uzela u obzir moguća neuravnoteženost klasa. Na temelju usporedbe rezultata različitih verzija modela odabrana je ona verzija modela koja je ostvarila najbolje performanse na testnom skupu.

9.4. Procjena modela

Procjena modela provedena je kroz proces optimizacije hiperparametara i evaluacije performansi korištenjem više evaluacijskih metrika. Nakon usporedbe Random Forest i XGBoost modela, Random Forest je odabran za daljnju optimizaciju jer je ostvario bolje rezultate na testnom skupu podataka.

Optimizacija hiperparametara provedena je kroz više konfiguracija Random Forest modela. Tijekom procesa mijenjani su parametri poput `n_estimators` (broj stabala odlučivanja), `max_depth` (maksimalna dubina stabala), `min_samples_leaf` (minimalni broj uzoraka u listovima) te parametra `class_weight`. Cilj optimizacije bio je pronaći konfiguraciju koja ostvaruje najbolje rezultate i pokazuje najveću uspješnost modela.

Performanse modela evaluirane su korištenjem metrika Accuracy, Precision, Recall i F1-Score koje pružaju uvid u kvalitetu klasifikacije. Accuracy mjeri ukupni udio ispravno klasificiranih primjera, Precision procjenjuje pouzdanost pozitivnih predikcija, Recall mjeri sposobnost modela da prepozna pozitivne primjere, dok F1-Score predstavlja mjeru koja objedinjuje Precision i Recall. Za detaljniju analizu dodatno je korištena matrica zabune, koja omogućuje uvid u broj točno i netočno klasificiranih primjera po klasama.

Rezultati evaluacije pokazali su da optimizirana verzija Random Forest modela ostvaruje najbolje vrijednosti Accuracy, Precision i F1-Score metrike, uz zadržavanje visoke vrijednosti Recall metrike. Analiza matrice zabune potvrdila je smanjenje broja pogrešnih klasifikacija u odnosu na početne verzije modela, posebno u pogledu lažno pozitivnih predikcija. Na temelju dobivenih rezultata zaključeno je da optimizirani Random Forest model pruža najbolje rezultate zbog čega je odabran kao konačno rješenje za predviđanje uspješnosti prodaje vozila na oglašivačkim platformama.

9.5. Analiza osjetljivosti

Analiza osjetljivosti provedena je korištenjem mjere važnosti značajki koja je dobivena iz Random Forest modela. Cilj je bio utvrditi koje varijable imaju najveći utjecaj na predviđanje uspješnosti prodaje vozila na pojedinoj oglašivačkoj platformi.

Rezultati pokazuju da najveći utjecaj imaju cijena vozila s udjelom od 23,51% i trenutna kilometraža s udjelom 21,55%. Zajedno ova dva čimbenika nose više od 45% ukupnog utjecaja u modelu, što potvrđuje da je financijski aspekt, uz kilometražu vozila, prvi eliminacijski kriterij za potencijalne kupce. Nakon toga značajan doprinos ima model vozila (12,62%) i starost vozila (7,80%). Među važnijim značajkama još se nalazi i brend s 5,39% utjecaja na uspješnost prodaje vozila.

Dobiveni rezultati ukazuju da su cijena i prijedeni kilometri najvažniji čimbenici koji utječu na vjerojatnost uspješne prodaje vozila na oglašivačkim platformama. Analiza također utvrđuje da karakteristike povezane s modelom i brendom vozila imaju značajnu ulogu u procesu donošenja odluka. Osim toga, značajan utjecaj CO₂ emisije upućuje na mogućnost da ekološke karakteristike vozila mogu imati određeni utjecaj na uspješnost prodaje.

10. Opis kriterija i određivanja težina metodom AHP

U svrhu provedbe AHP metode, polazište analize činile su značajke dobivene obradom sirovih podataka od strane kolega iz IPS-a, koje su nam proslijeđene za daljnju obradu. Iz dostupnog skupa značajka odabrali smo pet koje smatramo najrelevantnijim za rješavanje promatranog problema te smo ih definirali kao kriterije u AHP metodi. Kriteriji koji smo odabrali su: Brand, Price, Duration, Age i Current_mileage.

Odabrali smo kriterij *Brand* zato što smatramo da je to jedan od najvažnijih kriterija pri odabiru odgovarajuće platforme za oglašavanje, budući da kupci često imaju određene preferencije prema brendovima i markama automobila. Također, različite platforme bolje odgovaraju određenim segmentima kupaca jer sam brend značajno utječe na ponašanje i želje kupaca. Kriterij *Price* ima vrlo veliku važnost i utjecaj na konačnu odluku kupca. Različite platforme privlače različite tipove kupaca, a cijena je često presudan faktor pri odabiru automobila. Kriterij *Duration* je ukupno vrijeme trajanja oglasa od trenutka objave do trenutka prodaje. Ovaj je kriterij važan jer kupci mogu percipirati oglas koji dugo traje kao manje atraktivan ili kao potencijalni znak nedostataka na vozilu. Kriterij *Age* također utječe na preferencije kupaca jer većina preferira novije automobile, iako postoje i specifične potreba kupaca poput potražnje za oldtimer automobilima. Kriterij *Current_mileage* označava trenutnu kilometražu automobila. Kupci u pravilu preferiraju automobile s manjim brojem prijeđenih kilometara jer se oni često povezuju s novijim vozilima i manjim stupnjem istrošenosti.

Nakon što smo odredili kriterije, svih pet članova tima individualno je provelo usporedbu svih kriterija u parovima te su na temelju toga izračunale individualne težine pojedinih kriterija. Zatim je za svaki kriterij izračunat prosjek individualno dobivenih težina svih članova tima, čime su dobivene zajedničke težine kriterija. Rezultat su dobivene težine svakog pojedinačnog kriterija, koje prikazuju njegovu relativnu važnost. Što je težina veća, to je kriterij važniji u donošenju odluke.

Najvažniji kriterij, odnosno onaj s najvećom težinom bio je *Price* (0,31), što je bilo i očekivano s obzirom na to da je u današnje vrijeme cijena jedan od ključnih čimbenika pri odabiru automobila. Nakon kriterija *Price*, najveću važnost imaju kriteriji *Age* (0,24), *Brand* (0,22) i *Current_mileage* (0,15). Najmanju težinu ima kriterij *Duration* (0,09), jer iz perspektive kupaca ima najmanji utjecaj na donošenje odluke o kupnji automobila.

	Melanija	Helena	Patricija	Ela	Ena	Zajedno
Brand	0,18	0,20	0,20	0,28	0,22	0,22
Price	0,35	0,30	0,32	0,20	0,35	0,31
Duration	0,08	0,10	0,08	0,10	0,08	0,09
Age	0,24	0,26	0,19	0,28	0,25	0,24
Current_mileage	0,15	0,15	0,20	0,14	0,10	0,15
VehicleHub	0,3333333333	0,3333333333	0,3333333333	0,3333333333	0,3333333333	0,3333333333
AutoTradeNet	0,3333333333	0,3333333333	0,3333333333	0,3333333333	0,3333333333	0,3333333333
CarFinder	0,3333333333	0,3333333333	0,3333333333	0,3333333333	0,3333333333	0,3333333333

Tablica 16. AHP metoda

11. Usporedba rezultata AHP-a i analize osjetljivosti

Usporedbom rezultata AHP metode i analize osjetljivosti uočavamo da obje metode identificiraju cijenu vozila (Price) kao najvažniji kriterij odlučivanja. Zatim dolazi do značajnih razlika između AHP metode i analize osjetljivosti. AHP metoda veću važnost daje kriterijima kao što su Brand (22%) i Age (24%), dok nam analiza osjetljivosti prikazuje kako imaju mali utjecaj na konačni rezultat; Brand (5,39%) i Age (7,80%). Zatim imamo kriterij Current_mileage koji ima mnogo veću važnost kao kriterij u analizi osjetljivosti gdje iznosi 21,55%, a u AHP metodi iznosi 15%. Također, vidimo da dio kriterija nije zastupljen u obje tablice te zbog toga ne možemo napraviti usporedbu za sve kriterije koji se ne nalaze u tablici rezultata analize osjetljivosti i tablici rezultata dobivenih AHP metodom.


Rezultati nam pokazuju određene razlike, ali i sličnosti između težina kriterija dobivenih AHP metodom i analizom osjetljivosti. Također dobivene razlike mogu utjecati na našu konačnu odluku zato što promjena težine kriterija isto tako mijenja važnost alternativa. Vrlo važno je za spomenuti da veća odstupanja kod rezultata ovih dviju metoda dovode do promjena u poretku alternativa, a manja odstupanja kod rezultata ukazuju na stabilnost donesene odluke. U našem slučaju smatramo da razlike nisu toliko izražene da bi promijenile odluku, ali rezultati upućuju na to određeni kriterij kao npr. prijeđena kilometraža ima znatno veći utjecaj na rezultat nego što je to predviđeno AHP metodom. Zbog svega navedenog prilikom donošenja konačne odluke praktično je uzeti u obzir rezultate obje metode kako bi dobili što objektivniji prikaz važnosti kriterija.

12. Vrednovanje

12.1. Evaluacija rezultata

Evaluacija rezultata provedena je usporedbom performansi Random Forest i XGBoost modela i naknadnom analizom optimizirane verzije Random Forest modela. Za procjenu uspješnosti korištene su standardne klasifikacijske metrike Accuracy, Precision, Recall i F1-Score, kao i matrice zabune koje omogućuju detaljniji uvid u točnost klasifikacije po pojedinim klasama.


Matrice zabune za početne verzije Random Forest i XGBoost modela prikazane su na sljedećoj slici:



Slika 15: Matrice zabune početnih modela

Iz rezultata je vidljivo da Random Forest ostvaruje veći broj točno klasificiranih negativnih primjera (65 541 u odnosu na 62 795) uz nešto manji broj lažno pozitivnih predikcija. Iako XGBoost ostvaruje malo veći broj točno klasificiranih pozitivnih primjera, ukupne performanse Random Forest modela pokazale su se boljima što je potvrđeno i evaluacijskim metrikama.


Nakon optimizacije Random Forest modela dobivena je druga verzija modela s matricom zabune:



Slika 16: Matrice zabune optimiziranog modela

U odnosu na početnu verziju Random Forest modela, optimizirani model ostvaruje povećanje broja točno klasificiranih negativnih primjera (s 65 541 na 68 467) te smanjenje broja lažno pozitivnih predikcija (s 24 873 na 21 947). Istovremeno je zadržan gotovo jednak broj točno klasificiranih pozitivnih primjera uz smanjenje broja lažno negativnih klasifikacija. Navedena poboljšanja rezultirala

su višim vrijednostima metrika Accuracy, Precision i F1-Score, dok je Recall ostao na približno istoj razini. Slika ispod detaljnije prikazuje usporedbu evaluacijskih metrika za svaki model:



Slika 17: Usporedba metrika modela

Druga verzija Random Forest modela ostvarila je najviše vrijednosti metrika Accuracy, Precision i F1-Score u odnosu na ostale modele. Viša vrijednost Accuracy metrike ukazuje na veću ukupnu točnost klasifikacije, a bpovećanje Precision metrike pokazuje da model ostvaruje manji udio pogrešno pozitivnih predikcija. Viša vrijednost F1-Score metrike potvrđuje bolju ravnotežu između Precision i Recall pokazatelja. Vrijednost Recall metrike ostala je na približno istoj razini kod svih analiziranih modela što znači da optimizacija modela nije negativno utjecala na sposobnost modela da prepozna pozitivne primjere.

Na temelju ostvarenih rezultata zaključeno je da druga verzija Random Forest modela pruža najbolju kombinaciju točnosti, pouzdanosti predikcija i sposobnosti generalizacije. Dodatna prednost ove konfiguracije je primjena parametra `class_weight='balanced'`, kojim se smanjuje potencijalni utjecaj razlike u zastupljenosti pojedinih klasa. Zbog navedenih razloga druga verzija Random Forest modela odabrana je kao konačni model za daljnju primjenu.

12.2. Ocjenjivanje procesa

U procesu modeliranja odabrana je metoda Random Forest, nakon usporedbe s XGBoost algoritmom. Oba modela razvijena su i evaluirana na istom skupu podataka korištenjem jednakog postupka podjele podataka na skup za treniranje i testiranje. Rezultati evaluacije pokazali su da Random Forest ostvaruje bolje vrijednosti promatranih evaluacijskih metrika te je zbog toga odabran za daljnju optimizaciju i konačnu implementaciju.

Kvaliteta postupka evaluacije osigurana je korištenjem zasebnog testnog skupa na kojem modeli nisu bili trenirani. Za procjenu uspješnosti korištene su standardne klasifikacijske metrike Accuracy, Precision, Recall i F1-Score te matrica zabune. Takav pristup omogućio je procjenu performansi modela i usporedbu različitih konfiguracija tijekom procesa optimizacije.

Kako bi se dodatno procijenili dobiveni rezultati, provedena je usporedba važnosti kriterija dobivenih analizom osjetljivosti Random Forest modela i težina kriterija dobivenih primjenom AHP metode. Analiza osjetljivosti temeljena je na važnosti značajki iz modela, dok AHP metoda predstavlja procjenu važnosti pojedinih kriterija. Rezultati analize osjetljivosti pokazali su da najveći utjecaj na uspješnost prodaje imaju cijena vozila (23,51%) i trenutna kilometraža (21,55%). Slijede model vozila (12,62%), starost vozila (7,80%) te brend vozila (5,39%). S druge strane, AHP metoda dodijelila je najveću važnost cijeni vozila (31%), starosti vozila (24%),

brendu (22%) i trenutnoj kilometraži (15%), dok je kriterij koji označava trajanje dobio težinu od 9%. Usporedba rezultata pokazuje podudarnost između oba pristupa u pogledu identifikacije ključnih čimbenika. Obje metode potvrđuju da je cijena vozila najvažniji kriterij pri procjeni uspješnosti prodaje. Također, starost vozila, brend i kilometraža prepoznati su kao važni čimbenici u oba modela. Unatoč tome postoje određene razlike u težinama pojedinih kriterija. Random Forest model daje puno veću važnost kilometraži vozila nego AHP metoda, dok AHP analiza veću važnost pridaje starosti i brendu vozila. Takve razlike mogu se objasniti činjenicom da analiza osjetljivosti odražava stvarne obrasce pronađene u povijesnim podacima, a AHP metoda s druge strane predstavlja subjektivnu procjenu temeljenu na iskustvu i poslovnom znanju.

Dobiveni rezultati ukazuju da postoji visoka razina povezanosti između podataka dobivenih u AHP metodi i analizi osjetljivosti. Podudarnost u određivanju najvažnijih kriterija povećava povjerenje u razvijeni model i potvrđuje da model uspješno prepoznaje čimbenike koji su relevantni za donošenje odluka o uspješnosti prodaje vozila na oglašivačkim platformama.

12.3. Određivanje sljedećih koraka

Na temelju provedene analize podataka, razvoja modela i evaluacije rezultata identificirano je nekoliko mogućih smjerova daljnjeg razvoja projekta. Potencijalne aktivnosti uključuju dodatnu pripremu i proširenje skupa podataka, unaprjeđenje postojećeg prediktivnog modela, razvoj drugih modela i implementaciju razvijenog rješenja u stvarnom poslovnom okruženju.

Jedan od prioriteta za budući razvoj predstavlja prikupljanje stvarnih podataka o troškovima oglašavanja na pojedinim marketplace platformama. U trenutnoj analizi ROI je izračunat na temelju pretpostavljenih vrijednosti troškova, dok bi korištenje stvarnih podataka iz ugovora s partnerima omogućilo precizniju procjenu profitabilnosti pojedinih oglasnih kanala i povećalo poslovnu vrijednost rezultata. Dodatno poboljšanje modela moglo bi se ostvariti proširenjem skupa značajki. U budućim iteracijama projekta moguće je uključiti dodatne tržišne i ekonomske pokazatelje, podatke o potražnji za određenim vrstama vozila, sezonske čimbenike te informacije o konkurentskim oglasima. Takvi podaci mogli bi povećati prediktivnu moć modela i omogućiti bolje prepoznavanje obrazaca koji utječu na uspješnost prodaje vozila. Gledano sa strane modeliranja, moguće je provesti dodatnu optimizaciju Random Forest modela korištenjem drukčijih hiperparametara u kombinaciji s k-fold križnom validacijom. Na taj bi se način dobila pouzdanija procjena sposobnosti generalizacije modela te potencijalno ostvarila dodatna poboljšanja performansi. Također je moguće istražiti primjenu drugih algoritama strojnog učenja koji su se u sličnim klasifikacijskim problemima pokazali konkurentnima Random Forest i XGBoost algoritmima.

Nakon razmatranja navedenih mogućnosti, kao sljedeći korak projekta odabrano bi bilo implementiranje postojećeg modela u poslovno okruženje. Budući da je razvijeni Random Forest model ostvario zadovoljavajuće rezultate na testnom skupu podataka, njegova primjena omogućila bi automatsku procjenu uspješnosti oglasa i podršku pri donošenju odluka o odabiru marketplace platformi. Istovremeno bi se kroz rad u stvarnom okruženju mogli prikupljati dodatni podaci potrebni za buduće iteracije i daljnje unaprjeđenje modela.

13. Prijedlog i opis alternativa

Za rješavanje problema odabrane su tri alternative, odnosno tri platforme za oglašavanje vozila: VehicleHub, CarFinder i AutoTradeNet. Svaka od platformi omogućuje oglašavanje vozila i povezivanje prodavatelja s potencijalnim kupcima, ali se razlikuju po svojim karakteristikama.

VehicleHub je platforma na kojoj se nalazi velik broj oglasa vozila. Zbog velikog broja objavljenih oglasa vozila postižu veću vidljivost od strane potencijalnih kupaca što može rezultirati većim brojem pregleda te većom vjerojatnošću prodaje samog vozila. S druge strane, ograničenje ove platforme može biti teže isticanje pojedinog oglasa među konkurencijom.

CarFinder je platforma koja pruža korisnicima jednostavno pretraživanje vozila prema različitim kriterijima, pri čemu se naglasak stavlja na filtriranje i usporedbu dostupnih oglasa vozila. Takav pristup olakšava povezivanje vozila s kupcima koji imaju jasno definirane zahtjeve prilikom kupnje vozila. Ograničenje ove platforme može biti veća ovisnost o potpunosti i kvaliteti unesenih podataka o samom vozilu s obzirom na to da potencijalni kupci pretražuju vozila prema različitim kriterijima.

AutoTradeNet je platforma koja omogućuje prikaz vozila različitih kategorija te prikupljanje podataka o interesu kupaca kroz ostvarene leadove. Kao i ostale alternative, koristi se kao kanal za oglašavanje vozila. Ograničenje platforme može biti činjenica da sami ostvareni leadovi ne rezultiraju nužno i stvarnom kupnjom vozila.

Navedene alternative predstavljaju moguća rješenja za problem odabira odgovarajuće platforme za oglašavanje vozila. Njihovo vrednovanje provest će se primjenom AHP metode i prethodno definiranih kriterija odlučivanja.

14. Odabir najprikladnije alternative

Nakon definiranja alternativa, svaki student je proveo za sebe metodu usporedbe alternativa prema važnosti. Dobiveni su ukupni prioriteti svake pojedine alternative. Rezultati pokazuju da najveću vrijednost ostvaruje alternativa CarFinder koja ostvaruje vrijednost prioriteta od 0,377. Zatim slijede alternative Vehicle Hub s vrijednosti 0,34 i AutoTrade Net s vrijednosti prioriteta od 0,28. Dobiveni rezultat ukazuje na to da alternativa, odnosno oglašivačka platforma CarFinder ostvaruje prednost u odnosu na druge oglašivačke platforme, zbog toga jer platforma najbolje zadovoljava postavljene kriterije i nudi povoljan odnos između cijene, starosti i prijeđene kilometraže oglašanih vozila. S obzirom na rezultate analize, poslovna preporuka je koristiti platformu CarFinder kao primarnu platformu za oglašavanje vozila. Odluka je opravdana s obzirom da je najvažniji kriterij s najvećim utjecajem na odluku cijena, a CarFinder nudi najniže cijene vozila u usporedbi s platformama drugih konkurenata. Zaključno, preporuka je pridodati najviše pažnje prilikom oglašavanja platformi CarFinder. Platforma Vehicle Hub može služiti kao drugi kanal oglašavanja kojim se dodatno povećava vidljivost vozila kod samih kupaca, dok AutoTrade Net može služiti za oglašavanje samo određene kategorije vozila.

	Melanija	Helena	Patricija	Ela	Ena	Zajedno
Brand	0,18	0,20	0,20	0,28	0,22	0,22
Price	0,35	0,30	0,32	0,20	0,35	0,31
Duration	0,08	0,10	0,08	0,10	0,08	0,09
Age	0,24	0,26	0,19	0,28	0,25	0,24
Current_mileage	0,15	0,15	0,20	0,14	0,10	0,15
VehicleHub	0,3601543574	0,3207256065	0,3247521775	0,352452299	0,3574184536	0,3431005788
AutoTradeNet	0,2306687	0,3221827625	0,2970990732	0,3255073815	0,2259293802	0,2802774595
CarFinder	0,4091769426	0,357091631	0,3781487493	0,3220403195	0,4166521662	0,3766219617

Tablica 17. AHP metoda

15. Rizik implementacije odabrane alternative

Iako je provedena metoda pokazala da je CarFinder najprikladnija alternativa, njezina implementacija uključuje određene rizike, ograničenja i neizvjesnosti koje mogu utjecati na ostvarenje očekivanih rezultata. Mogući rizici su sljedeći:

Rizik kvalitete podataka o vozilima

CarFinder se u velikoj mjeri oslanja na točnost i potpunost podataka o vozilu jer korisnici pretražuju oglase koristeći filtre kao što su marka, model, cijena, godina proizvodnje i kilometraža. Netočni ili nepotpuni podaci mogu smanjiti vidljivost oglasa i dovesti do manjeg broja relevantnih upita. Ovaj rizik moguće je ublažiti redovitom kontrolom kvalitete podataka te automatiziranom provjerom unesenih informacija prije objave oglasa.

Rizik promjene ponašanja kupaca

Interesi i preferencije kupaca na tržištu vozila kontinuirano se mijenjaju. Kupci mogu izabrati druge platforme ili drugačije načine pretraživanja vozila, što može smanjiti učinkovitost CarFinder-a. Kako bismo smanjili ovaj rizik, potrebno je kontinuirano pratiti tržišne trendove i prilagođavati strategiju oglašavanja novim kupčevim navikama.

Rizik konkurentskih platformi

Platforme poput VehicleHub-a i AutoTradeNeta mogu unaprijediti svoje funkcionalnosti ili ponuditi povoljnije uvjete oglašavanja. Takve promjene mogu smanjiti konkurentsku prednost CarFinder-a i utjecati na njegovu učinkovitost. Rizik se može ublažiti redovitim praćenjem rezultata svih dostupnih platformi te periodičnim preispitivanjem odabrane strategije oglašavanja.

Rizik niske konverzije oglasa u prodaji

Iako CarFinder omogućuje kvalitetnije povezivanje vozila s potencijalnim kupcima, ne postoji jamstvo da će interes kupaca rezultirati stvarnom kupnjom vozila. Na konačnu odluku kupca utječu brojni čimbenici poput cijene, dostupnosti financiranja ili konkurentske ponude. Rizik se može smanjiti praćenjem pokazatelja konverzije te optimizacijom sadržaja oglasa i komunikacije s kupcima.

Tehnološki rizik

Moguće su tehničke poteškoće povezane s integracijom podataka između internih sustava poduzeća i platforme CarFinder. Također, promjene u načinu rada platforme ili privremeni tehnički problemi mogu utjecati na dostupnost oglasa. Ovaj rizik može se ublažiti redovitim održavanjem sustava, testiranjem integracija i osiguravanjem tehničke podrške.

Rizik promjene uvjeta poslovanja

CarFinder može u budućnosti promijeniti modele naplate, pravila objavljivanja oglasa ili algoritme prikaza sadržaja. Takve promjene mogu povećati troškove oglašavanja ili smanjiti vidljivost oglasa. Kako bi se rizik ublažio, potrebno je kontinuirano pratiti uvjete poslovanja i zadržavati mogućnosti korištenja alternativnih platformi.

Organizacijski rizik

Uspješna implementacija zahtijeva pravilno korištenje rezultata analize i prilagodbu poslovnih procesa. Nedovoljna educiranost zaposlenika ili otpor prema promjenama mogu smanjiti učinkovitost primjene odabrane platforme. Edukacijom zaposlenika i jasnim definiranjem postupaka rada smanjio bi se ovaj rizik.

Glavni rizici implementacije CarFinder-a povezani su s kvalitetom podataka, promjenama tržišnih uvjeta, konkurencijom drugih platformi i mogućim tehnološkim ograničenjima. Redovitim praćenjem rezultata, održavanjem kvalitete podataka i prilagodbom strategije oglašavanja moguće je značajno smanjiti utjecaj navedenih rizika te osigurati uspješnu primjenu odabrane alternative.

16. Etička strana odabrane alternative

Na temelju provedene AHP analize, odabrana alternativa je platforma CarFinder, koja je ostvarila ukupni prioritet od 0,377 ispred VehicleHuba (0,343) i AutoTradeNeta (0,280). Ova odluka potkrijepljena je i rezultatima segmentacijske analize te ROI kalkulacije iz podatkovnog modela, koji pokazuju da CarFinder ostvaruje dobar balans između stope konverzije, vremena prodaje i troška oglašavanja za većinu segmenata vozila. U kontekstu etičke procjene, važno je naglasiti da odabir CarFindera kao primarne platforme ne isključuje korištenje ostalih kanala. VehicleHub ostaje ključan za ekonomski segment i masovne brendove, a AutoTradeNet za luxury i premium kategoriju.

16.1. Utjecaj na dionike

Menadžment i prodajni tim Emil Frey Digital najizravniji su korisnici sustava potpore odlučivanju. Jedno od pitanja koje se pojavljuje pri uvođenju ovakvog alata je može li tim steći dojam da model zamjenjuje njihovu prosudbu umjesto da je samo podupire. Ovakva percepcija posebno je rizična u situacijama gdje pouzdanost preporuke nije visoka, na primjer u segmentima s malim brojem podataka. Iz tog razloga sustav preporuka, koji se temelji na funkciji preporuci(), prikazuje metrike (CR%, TTS i ROI%) uz svaku preporuku, a u segmentima s malo podataka preporuka se treba tretirati kao smjernica, a ne konačna odluka. Kroz cijelu studiju slučaja naglašava se da model samo identificira obrasce i predlaže moguće opcije, a konačna odluka i dalje ostaje na menadžmentu.

Krajnji kupci vozila neizravno su pogođeni odabirom platformi za oglašavanje. Optimizacijom prema ROI-u, vozila ekonomskog segmenta (< 15.000 €) sustavno se usmjeravaju isključivo na VehicleHub jer je to jedina platforma s pozitivnim ROI-jem u tom segmentu. Kao posljedica toga vidljivost tih vozila na CarFinderu i AutoTradeNetu može biti smanjena što znači da ih kupci koji pretražuju isključivo te platforme možda neće pronaći. Osim toga bitno je napomenuti da električna vozila na svim platformama bilježe najdulje prosječno vrijeme prodaje (283–295 dana) što ukazuje na potrebu posebne strategije vidljivosti za tu kategoriju.

Platforme kao poslovni partneri također su neizravno pogođene odlukama koje sustav preporučuje. Ako model dosljedno preporučuje smanjenje broja objava na AutoTradeNetu za segmente s negativnim ROI-jem, to može narušiti ugovorene odnose s tom platformom. Taj poslovni rizik treba uzeti u obzir pri donošenju oglašivačkih odluka, neovisno o tome što model preporučuje.

16.2. Pravednost i potencijalna pristranost modela

Analiza osjetljivosti (feature importance) finalnog Random Forest modela (100 stabala, class_weight='balanced') pokazuje da PRICE (23,51%) i CURRENT_MILEAGE (21,55%) zajedno čine gotovo 45% ukupnog prediktivnog utjecaja, dok MODEL_VERSION_FREQ (12,62%), AGE (7,80%) i CO2_EMISSION (7,62%) doprinose manjim, ali značajnim udjelima. Ova distribucija ukazuje na potencijalni problem pravednosti gdje model favorizira skuplja i novija vozila jer su statistički češće vezana uz uspješnu prodaju (CONTRACT_STATUS = 1) u podacima za trening.

Usporedbom s AHP težinama kriterija uočava se da se kriteriji djelomično podudaraju. Price je i u AHP analizi najvažniji kriterij (0,31), dok Age zauzima drugu poziciju (0,24), što je konzistentno s poretkom feature importancea. Međutim, analiza osjetljivosti pokazuje da CURRENT_MILEAGE (21,55%) ima znatno veći stvarni utjecaj nego što je predviđeno AHP metodom (0,15). Ova razlika govori o tome da postoji jaz između poslovnog pogleda na važnost pojedinih kriterija i onoga što podaci otkrivaju kao stvarne kriterije koji utječu na uspješnost prodaje vozila. To daje korisnu informaciju za buduće iteracije AHP analize.

Bitno je naglasiti da ROI formula koristi fiktivne vrijednosti troškova oglašavanja (30–80€/oglas, 1% provizija) i maržu od 7% prema Arthur D. Little (2023). Dobivene ROI vrijednosti zbog toga nisu pouzdan poslovni i financijski pokazatelj. Analiza po marketplaceu koja kombinira konverzijsku stopu (70%) i prihod (30%) u zajednički roi_score daje visok ukupni score za AutoTradeNet na razini cijelog skupa podataka. To nije suprotno preporukama modela već ono odražava činjenicu da AutoTradeNet statistički privlači veći udio premium i luxury segmenata koji imaju visoke konverzijske stope i visoke cijene vozila, pa opći prosjek prirodno ide

njemu u korist. Segmentirana analiza, koja uzima u obzir tip vozila i cjenovni segment, daje konkretnije i praktički korisnije preporuke od ukupnog prosjeka.

16.3. Transparentnost i odgovornost u provedbi

Transparentnost sustava osigurana je kroz nekoliko slojeva koji su ugrađeni u programsko rješenje. Segmentacijska analiza prikazuje heatmape ROI-a, CR-a i TTS-a po segmentima, sezonama, tipovima karoserije i godinama proizvodnje što menadžmentu omogućuje praćenje logike svake preporuke bez potrebe za razumijevanjem tehničkih detalja algoritima.

Sezonska analiza dodaje i vremensku dimenziju preporukama. Sustav ne preporučuje samo koji kanal koristiti, već i u kojoj je sezoni CR% za određeni segment vozila na toj platformi najviši što dodatno povećava praktičnu korisnost preporuka.

Odgovornost za konačnu odluku ostaje na menadžmentu. Ovo je posebno važno u slučaju preporuka za gašenje kanala s negativnim ROI-jem. Takve odluke trebaju biti potkrijepljene i poslovnim kontekstom koji model ne može u potpunosti obuhvatiti, kao što su dugoročne ugovorne obveze prema platformama ili strateškim ciljevima vidljivosti pojedinog brenda na određenom tržištu.

16.4. Pregled etičkih rizika i mjera ublažavanja

U tablici ispod prikazani su identificirani etički rizici implementacije odabrane alternative zajedno s predloženim mjerama ublažavanja.

Etički rizik	Opis rizika	Mjera ublažavanja
Pristranost prema skupljim i novijim vozilima	PRICE (23,51%) i CURRENT_MILEAGE (21,55%) zajedno čine ~46% prediktivnog utjecaja modela. Ekonomski segment (< 15.000 €) sustavno se usmjerava isključivo na VehicleHub jer je jedina platforma s pozitivnim ROI-jem u tom segmentu, što ograničava vidljivost tih vozila na ostalim kanalima.	ROI formula uspoređuje kanale unutar istog segmenta, a ne apsolutne vrijednosti, čime se ublažava pristranost. Dodatno, preporuka za ekonomski segment nije da se gase ostale platforme, već da se smanje ulaganja; odluka ostaje na menadžmentu.
Ponavljanje povijesnih obrazaca	Model je treniran na povijesnim podacima koji odražavaju prethodne marketinške strategije. Kanali koji su u prošlosti bili podcijenjeni pojavljuju se s manje podataka te model može reproducirati takve obrasce i u budućnosti.	Tromjesečni retraining modela s novim podacima; uvođenje A/B testiranja novih platformskih strategija neovisno o preporukama modela, kako bi se generirani novi podaci ravnomjerno pokrili sve kanale.
Utjecaj na zaposlenike prodajnog tima	Uvođenje DSS-a može stvoriti percepciju da sustav zamjenjuje ljudsku prosudbu pri donošenju oglašivačkih odluka, što može dovesti do otpora prema promjeni ili, suprotno, prekomjernog oslanjanja na preporuke modela bez kritičke provjere.	Jasno komunicirati da model predlaže, a odluku donosi prodajni tim. Edukacija zaposlenika o interpretaciji CR%, TTS i ROI% metrika te o situacijama u kojima je ispravno zanemariti preporuku modela osigurava informiranu i odgovornu upotrebu sustava.
Transparentnost ROI pretpostavki	ROI formula koristi fiktivne aproksimacije troškova oglašavanja i margin od 7%. Apsolutne ROI vrijednosti nisu pouzdan poslovni pokazatelj, relevantna je	Eksplícitno naznačiti u DSS sučelju da su ROI vrijednosti komparativne aproksimacije, a ne apsolutni poslovni pokazatelji. Odluke o gašenju kanala ne smiju se temeljiti isključivo na ROI

	isključivo relativna razlika između kanala unutar istog segmenta.	iznosu, već i na poslovnom kontekstu koji model ne obuhvaća.
--	---	--

Tablica 18. Etički rizici implementacije CarFindera kao odabrane alternative i mjere ublažavanja

Može se zaključiti da je odabir CarFindera kao primarne oglašivačke platforme etički prihvatljiv uz uvjet da se dosljedno primijene mjere ublažavanja. Ključni etički uvjeti su:

1. model je isključivo alat za potporu odlučivanju i ne donosi odluke samostalno;
2. preporuke su potkrijepljene konkretnim metrikama (CR%, TTS, ROI%);
3. ROI vrijednosti jasno su označene kao aproksimacije;
4. svi dionici, uključujući prodajni tim, moraju biti informirani o načinu rada i ograničenjima sustava.

17. Plan realizacije odabrane alternative

Plan realizacije definira vremenski okvir, potrebne resurse i korake provedbe za implementaciju odabrane alternative odnosno platforme CarFinder kao primarnog kanala za oglašavanje vozila, uz povremenu upotrebu VehicleHuba i AutoTradeNeta ovisno o segmentu vozila. Plan je napisan kao prijedlog implementacije koji Emil Frey Digital može koristiti kao osnovu za poslovnu odluku.

17.1. Troškovi platformi i osnova za ROI kalkulaciju

Za razumijevanje preporuka po segmentu važno je shvatiti troškove svake platforme koji su prikazani u tablici ispod. Ove vrijednosti trebaju biti zamijenjene sa stvarnim ugovorenim cijenama u trenutku primjene u sustavu.

Marketplace	Cijena oglasa	Provizija	Karakteristike i uloga
VehicleHub	30 €	1% od cijene vozila	Najniži trošak oglašavanja; niži CR u većini segmenata, ali visok ROI za masovne brendove s velikim volumenom (VW, Ford, Opel). Jedina platforma s pozitivnim ROI-jem za ekonomski segment (< 15.000 €).
CarFinder	50 €	1% od cijene vozila	Odabrana primarna platforma. Dobar balans između CR-a i ROI-ja; kraće prosječno TTS u većini segmenata. Score koji kombinira ROI, CR i TTS (svaki s težinom 0,33) konzistentno visok za srednji i obiteljski segment.
AutoTradeNet	80 €	1% od cijene vozila	Najviši trošak; visok CR (56–70% ovisno o segmentu), ali niži ROI zbog veće cijene oglasa. Preporučuje se selektivno za luxury i premium segment gdje marža apsorbira trošak.

Tablica 19. Struktura troškova marketplace kanala i njihova uloga u sustavu preporuka

ROI se izračunava kao $(\text{prihod} - \text{ukupni trošak}) / \text{ukupni trošak} \times 100$, pri čemu $\text{prihod} = \text{CR} \times 0,07 \times \text{medijan cijene segmenta (marža 7\%)}$, a $\text{ukupni trošak} = \text{cijena oglasa} + 1\% \times \text{medijan cijene segmenta}$.

Analiza po platformi pokazuje visok ukupni score za AutoTradeNet na razini cijelog skupa podataka što je posljedica toga što ta platforma privlači više premium i luxury vozila. Budući da su troškovi oglašavanja aproksimacije, ova opća analiza služi isključivo kao relativni pokazatelj i ona ne mijenja segmentirane preporuke prikazane u tablici ispod.

Segment	Primarni kanal	Smanjiti / isključiti	Obrazloženje
Električni	AutoTradeNet	---	Električna vozila imaju najdulje TTS (283–295 dana na svim platformama). AutoTradeNet ostvaruje visok CR; razlika u ROI-ju između kanala je manja zbog visokih cijena vozila.
Hibridni	CarFinder	VehicleHub	CarFinder (47,41% CR) nadmašuje VehicleHub (41,06%) uz niži trošak, što rezultira boljim ROI-jem i preporučuje se kao primarni kanal.
Luxury	AutoTradeNet	---	AutoTradeNet privlači luxury kupce; CarFinder i VehicleHub bilježe manji volumen luxury oglasa i nižu pouzdanost preporuke u tom segmentu.
Sportski	CarFinder	VehicleHub	CarFinder ostvaruje kraći TTS za sportska vozila uz dobar CR; VehicleHub je prihvatljiva alternativa za masovnije brendove u ovom segmentu.
Premium novi	AutoTradeNet	VehicleHub	Visoka cijena vozila kompenzira viši trošak AutoTradeNeta; ROI razlike između kanala manje su izražene nego u ekonomskim segmentima.
Premium rabljeni	CarFinder	---	Rabljeni premium segment bolje prolazi na CarFinderu koji privlači cjenovno osjetljivije premium kupce s jasno definiranim zahtjevima.
Premium	AutoTradeNet	---	Premium segment konzistentno ostvaruje visok CR na AutoTradeNetu; preporuča se kao primarni kanal za ovu kategoriju vozila.
Obiteljski	CarFinder	VehicleHub	CarFinder je preporučeni default za obiteljska vozila (MPV, Station Wagon, 15–40k €); VehicleHub je isplativ za masovne brendove s visokim volumenom oglasa.
Obiteljski rabljeni	CarFinder	VehicleHub	CarFinder postiže kraće TTS (101 dan) u usporedbi s AutoTradeNetom (127 dana), što ga čini preferiranim izborom za rabljeni obiteljski segment.
Srednji	CarFinder	---	CarFinder nudi optimalan balans CR-a i troška za srednji cjenovni segment

			(15.000–40.000 €); preporuča se kao jedini primarni kanal.
Srednji rabljeni	CarFinder	VehicleHub	Najkraći TTS na CarFinderu; VehicleHub je alternativa posebno za masovne brendove (VW, Ford, Opel, Peugeot) s visokim volumenom u ovom segmentu.
Ekonomski	VehicleHub	CarFinder, AutoTradeNet	Jedino VehicleHub (30 €/oglas) ostvaruje pozitivan ROI u ekonomskom segmentu. CarFinder i AutoTradeNet bilježe negativan ROI zbog troška koji premašuje ostvarenu maržu.

Tablica 20. Preporuke po segmentu vozila — primarni kanal i kanali za smanjenje ulaganja

17.2. Vremenski okvir realizacije

Predloženi plan realizacije podijeljen je na šest faza koje se djelomično vremenski preklapaju, a ukupno trajanje je 12 tjedana. Vremenski raspored faza prikazan je u tablici ispod.

Faza realizacije	Trajanje	T1	T2	T3	T4	T5	T6	T7	T8	T9	T10	T11	T12
1. Analiza i dokumentacija	2 tjedna	▪	▪										
2. Priprema podataka	3 tjedna	▪	▪	▪									
3. Razvoj i validacija modela	3 tjedna			▪	▪	▪							
4. Razvoj DSS	4 tjedna					▪	▪	▪	▪				
5. Pilot implementacija i testiranje	3 tjedna								▪	▪	▪		
6. Evaluacija i uvođenje	2 tjedna										▪	▪	▪

Tablica 21. Vremenski plan realizacije odabrane alternative

Prva faza obuhvaća analizu i dokumentaciju trenutnog stanja, pregled postojećih podataka, definiranje zahtjeva za automatizacijom dohвата podataka i usklađivanje s IT infrastrukturom Emil Frey Digitala. Posebno se dokumentira logika segmentacije (12 segmenata definiranih kombinacijom varijabli PRICE, FUEL_TYPE, BODY_TYPE, AGE i CURRENT_MILEAGE) i ROI formula kako bi svi uključeni imali isti okvir.

Druga faza usmjerena je na zamjenu ručnog exporta datoteka automatiziranim dohvatom iz sustava kako bi model uvijek primao aktualne podatke. Automatizacija obuhvaća sva četiri izvorna skupa podataka: publishing_data, leads_data, offer_data i contract_data.

Treća faza podrazumijeva provjeru stabilnosti segmentacijske logike i ROI preporuka na aktualnim podacima zajedno s cross-validacijom Random Forest modela.

Četvrta faza obuhvaća razvoj sučelja koje prodajnom timu omogućuje jednostavno korištenje preporuka. Sučelje koristi funkciju `preporuci()` koja prima karakteristike vozila (gorivo, tip, cijena, starost, kilometraža) i vraća rangirane preporuke po oglašivačkoj platformi. Svaka preporuka prikazuje CR%, TTS i ROI% za sve tri platforme i jasno označava preporučeni primarni kanal.

Peta faza je pilot implementacija na ograničenom skupu vozila. Posebna se pozornost posvećuje segmentima s dovoljnim brojem podataka za pouzdane zaključke, dok se preporuke za segmente s malim volumenom oglasa koriste opreznije. Na temelju rezultata pilota donosi se odluka o eventualnim izmjenama modela prije punog uvođenja.

Šesta faza uključuje evaluaciju rezultata pilota, usporedbu ROI-ja za vozila oglašavana prema preporukama sustava nasuprot onima bez preporuka te pripremu za uvođenje. U ovoj se fazi definiraju i procesi za tromjesečni retraining modela i praćenje ključnih metrika u produkcijskom okruženju.

17.3. Potrebni resursi

Za uspješnu realizaciju odabrane alternative potrebni su resursi u pet kategorija, prikazanih u tablici ispod.

Kategorija	Resurs	Opis
Ljudski resursi	Tim (9 članova)	Data scientist (modeliranje i pipeline), business analitičar (poslovne preporuke i AHP), IT integrator (deployment i API), prodajni konzultant (validacija preporuka u poslovnom kontekstu)
Tehnički resursi	Programska okolina	Python (pandas, scikit-learn, XGBoost), Jupyter Notebook, Power BI ili Streamlit za DSS dashboard, Git za verzioniranje koda
Podatkovni resursi	Podaci za rad	Pristup aktualnim podacima iz CRM/ERP sustava Emil Frey Digital (publishing, leads, offers, contracts); zamjena ručnog exporta <code>df_najnoviji.csv</code> automatiziranim dohvatom u produkcijskom okruženju
Financijski resursi	Troškovi platformi	CarFinder: 50 € / oglas + 1% provizija (primarna platforma); VehicleHub: 30 € / oglas + 1% provizija (sekundarna); AutoTradeNet: 80 € / oglas + 1% provizija (selektivno za luxury/premium)
Infrastrukturni resursi	Deployment okolina	Server za model inference, REST API za funkciju <code>preporuci()</code> , monitoring CR%, TTS i ROI% metrika u produkcijskom okruženju

Tablica 22. Pregled potrebnih resursa za realizaciju odabrane alternative

17.4. Koraci realizacije

Korak 1: Uspostava automatiziranog podatkovnog toka. Zamjena ručnog CSV exporta automatiziranim dohvatom podataka iz internog sustava Emil Frey Digital. Bez ovog koraka model ostaje ovisan o ručnim intervencijama. Podaci o objavama, leadovima, ponudama i ugovorima trebaju biti dostupni u realnom vremenu kako bi preporuke pratile aktualnu situaciju na tržištu.

Korak 2: Postavljanje segmentacijske logike i ROI kalkulatora kao API servisa. Segmentacijska logika (funkcija `dodijeli_segment()`) i ROI kalkulator postavljaju se kao API servis koji prima karakteristike vozila kao ulazni zahtjev i vraća: segment vozila, preporučeni primarni kanal s CR%, TTS i ROI% za sve platforme, razinu pouzdanosti preporuke i predložene kanale oglašavanja.

Korak 3: Razvoj korisničkog sučelja za prodajni tim. Preporuča se Power BI dashboard ili Streamlit aplikacija u kojoj prodajni tim unosi karakteristike vozila i odmah dobiva rangirane preporuke s CR%, TTS i ROI% metrikama. Menadžment može pratiti heatmap i sezonske preporuke bez direktnog rada s kodom.

Korak 4: Edukacija prodajnog tima i upravljanje promjenom. Edukacija obuhvaća razumijevanje logike segmentacije i 12 definiranih segmenata vozila, interpretaciju CR%, TTS i ROI% metrika u kontekstu specifičnih segmenata te jasne upute o situacijama u kojima je ispravno zanemariti preporuku modela posebno za segmente s niskom pouzdanošću ili kod vozila na granicama segmentnih razreda. Ovaj korak osigurava da preporuke ostanu alat koji služi kao pomoć, a ne naredba.

Korak 5: Praćenje i retraining. Tromjesečni retraining s novim podacima uz praćenje CR%, ROI%, TTS-a i broj oglasa po segmentu. Sezonske preporuke trebaju biti ažurirane barem jednom godišnje.

17.5. Kriteriji uspješnosti realizacije

Uspješnost realizacije predložene alternative mjerit će se kroz sljedeće kriterije:

Povećanje stope konverzije (CR%) za vozila oglašavana prema preporukama sustava u usporedbi s vozilima bez preporuka, mjereno po završetku pilot faze.

Smanjenje prosječnog troška po prodanom vozilu, posebno za ekonomski segment gdje isključiva upotreba VehicleHuba (30€/oglas) uklanja negativni ROI koji je prisutan na skupljim platformama.

Skraćenje prosječnog vremena prodaje (TTS) usmjeravanjem vozila na kanale s kraćim medijanom TTS-a za taj segment. Na primjer obiteljski rabljeni segment ostvaruje TTS od 101 dana na CarFinderu nasuprot 127 dana na AutoTradNetu.

Povećanje ROI-ja oglašavanja mjereno relativnom razlikom između prihoda i troška po kanalu unutar istog segmenta u usporedbi s ROI-jem prethodnog perioda bez segmentiranih preporuka.

Zadovoljstvo prodajnog tima sustavom, mjereno kroz upitnik nakon pilot faze s naglaskom na praktičnost i razumljivost preporuka koje generira funkcija `preporuci()`.

Postizanje navedenih kriterija unutar definiranog vremenskog okvira potvrdit će da je odabrana alternativa CarFinder kao primarna platforma uz segmentiranu primjenu ostalih kanala uspješno realizirana te da pruža stvarnu poslovnu vrijednost Emil Frey Digital grupaciji u optimizaciji digitalne prodaje rabljenih vozila.

18. Završna razmatranja i preporuke

Provedena analiza sastoji se od kombinacije analize podataka, segmentacije tržišta, izračuna ROI-ja, razvoja prediktivnog modela i AHP metode. Svaki od tih pristupa promatra problem iz drugog kuta, zbog čega se preporuke za odabir najbolje platforme djelomično razlikuju.

Segmentacijska analiza izdvojila je 12 segmenata vozila prema cijeni, vrsti goriva, tipu karoserije, starosti i kilometraži. Za svaki segment izračunati su konverzija, vrijeme prodaje i ROI za pojedinu platformu. Na razini cijelog skupa podataka AutoTradeNet ostvaruje najviši ROI zbog dobrih rezultata u premium, luxury i električnim segmentima. Za ekonomična vozila zabilježeni su slabiji rezultati, dok CarFinder i VehicleHub ostvaruju bolji omjer troškova i prodaje u segmentima koji čine najveći dio ponude vozila. To pokazuje da ne postoji jedna najbolja platforma za sve vrste vozila i da segmentirani pristup donosi bolje rezultate.

AHP analiza promatrala je važnost kriterija cijene, starosti, brenda, kilometraže i trajanja oglasa. Prema dobivenim rezultatima, CarFinder je ostvario najveću ukupnu ocjenu (0,377), nakon njega slijedi VehicleHub (0,343) i AutoTradeNet (0,280). Ovi rezultati podupiru preporuku da CarFinder bude glavni kanal oglašavanja za većinu vozila, dok je AutoTradeNet prikladniji za premium, luxury i električna vozila, a VehicleHub za ekonomična vozila i brendove s velikim brojem oglasa.

Usporedba AHP metode i analize osjetljivosti pokazuje da obje metode prepoznaju cijenu kao najvažniji kriterij. S druge strane, model strojnog učenja pridaje veću važnost kilometraži nego AHP analiza. Takve razlike mogu se pripisati tome da AHP označava stručnu procjenu važnosti kriterija, dok analiza osjetljivosti pokazuje koji kriteriji u stvarnosti najviše utječu na uspješnost prodaje. Zbog toga je preporučljivo uzeti u obzir rezultate obje metode prilikom donošenja poslovnih odluka.

Rezultati pokazuju da CarFinder ostvaruje veću konverziju od AutoTradeNeta u većini cjenovnih segmenata, posebno kod vozila niže i srednje vrijednosti. Također, kod starijih vozila i vozila s većom kilometražom CarFinder zadržava visoku razinu konverzije, dok rezultati AutoTradeNeta padaju. To upućuje na zaključak da bi se takva vozila trebala prvenstveno oglašavati na CarFinderu. Za električna, hibridna i premium vozila AutoTradeNet ostvaruje bolje rezultate te se pokazuje kao prikladnija platforma za te segmente. Analiza također pokazuje da se različiti brendovi ponašaju različito. Za primjer se može uzeti BMW koji ostvaruje vrlo dobre rezultate na CarFinderu, dok Audi u najvišem cjenovnom segmentu postiže bolju konverziju na AutoTradeNetu. To potvrđuje da odabir platforme treba prilagoditi karakteristikama vozila. Posebnu pažnju zaslužuju SUV vozila koja čine najveći dio analiziranog skupa podataka. Noviji SUV modeli s manjom kilometražom postižu bolje rezultate na AutoTradeNetu, dok stariji SUV modeli ostvaruju veću uspješnost na CarFinderu. Ovakvi rezultati dodatno potvrđuju vrijednost segmentiranog pristupa oglašavanju.

Važno je napomenuti da su troškovi korišteni u ROI analizi procijenjene, a ne stvarne vrijednosti troškova oglašavanja. Zbog toga se ROI rezultati trebaju promatrati prvenstveno kao usporedba platformi unutar pojedinog segmenta, a ne kao stvarni pokazatelj profitabilnosti. Primjenom predloženog pristupa Emil Frey Digital može donositi odluke o oglašavanju na temelju podataka, smanjiti troškove i povećati učinkovitost prodaje vozila.

19. Poveznica na programski kod

https://colab.research.google.com/drive/1rv7DI-5qNa6pvB5g5_RUHw0p2autwDXP

20. Literatura

1. Emil Frey Digital (n.d.). *Emil Frey Digital*. Preuzeto 6. travnja 2026., s <https://emilfreydigital.com/>
2. Joberty (n.d.). *Emil Frey Digital overview*. Preuzeto 6. travnja 2026., s <https://www.joberty.com/it-company/5091/emil-frey-digital.overview>
3. Porsche Digital (n.d.) *Porsche Digital Croatia*. Preuzeto 8. travnja 2026. s <https://www.porsche-digital.hr/en>
4. Incadea (n.d.). *Incadea*. Preuzeto 8. travnja 2026. s <https://www.incadea.com/>
5. Nextlane (n.d.). *Nextlane*. Preuzeto 8. travnja 2026. s <https://www.nextlane.com/>
6. Fina Info.Biz (n.d.). *Emil Frey Digital d.o.o.* Preuzeto 9. travnja 2026. s <https://infobiz.fina.hr/tvrtka/emil-frey-digital-d-o-o/OIB-08209774427>

21. Prilozi

Popis tablica

Tablica 1. Struktura podataka contract data

Tablica 2. Moguće vrijednosti stupca CONTRACT_STATUS

Tablica 3. Struktura podataka leads data

Tablica 4. Moguće vrijednosti stupca LEAD_STATUS

Tablica 5. Struktura podataka offer data

Tablica 6. Moguće vrijednosti stupca OFFER_STATUS

Tablica 7. Struktura podataka publishing data

Tablica 8. Moguće vrijednosti stupca PUBLISH_STATUS

Tablica 9. Contract_data

Tablica 10. Offer_data

Tablica 11. Leads_data

Tablica 12. Publishing_data

Tablica 13. Statistička analiza numeričkih varijabli

Tablica 14. Nedostajuće vrijednosti po varijablama

Tablica 15. Stupci nakon integracije

Tablica 16. AHP metoda

Tablica 17. AHP metoda

Tablica 18. Etički rizici implementacije CarFindera kao odabrane alternative i mjere ublažavanja

Tablica 19. Struktura troškova marketplace kanala i njihova uloga u sustavu preporuka

Tablica 20. Preporuke po segmentu vozila — primarni kanal i kanali za smanjenje ulaganja

Tablica 21. Vremenski plan realizacije odabrane alternative

Tablica 22. Pregled potrebnih resursa za realizaciju odabrane alternative

Popis slika

Slika 1: Prikaz distribucije statusa ugovora

Slika 2: Distribucija varijable MARKETPLACE

Slika 3: Distribucija varijable PRICE

Slika 4: Distribucija varijable PRODUCTION_YEAR

Slika 5: Distribucija varijable CURRENT_MILEAGE

Slika 6: Odnos između cijene i kilometraže

Slika 7: Prikaz stršila za varijablu CO2_EMISSION

Slika 8: Prikaz stršila za varijablu CURRENT_MILEAGE

Slika 9: Prikaz stršila za varijablu PRICE

Slika 10: Prikaz stršila za varijablu PRODUCTION_YEAR

Slika 11: Box plot dijagram za prikaz CO2_EMISSION

Slika 12: Box plot dijagram za prikaz CURRENT_MILEAGE

Slika 13: Box plot dijagram za prikaz PRICE

Slika 14: Box plot dijagram za prikaz PRODUCTION_YEAR

Slika 15: Matrice zabune početnih modela

Slika 16: Matrice zabune optimiziranog modela

Slika 17: Usporedba metrika modela